Rapport de stage final

Intégration, caractérisation et validation d'un capteur de mouvement pour un dispositif sonore interactif embarqué

Auteur
Maël LELIEVRE

Master 2 Acoustique et Musicologie,
Parcours Ingénierie et Conception Sonore
UFR ALLSH - Aix-Marseille Université
Année Universitaire 2025 - 2026

Organisme d'accueil
Institut de Recherche et Coordination Acoustique/Musique (Ircam)
UMR STMS, Équipe Interaction Son Musique Mouvement (ISMM)

Encadrant de stage
Benjamin MATUSZEWSKI

Responsable pédagogique
Mathieu BARTHET

amU Faculté des arts, lettres, langues, sciences humaines
Aix Marseille Université

ircam Centre Pompidou

Résumé

Le framework web CoMo, initialement développé autour des smartphones, doit pouvoir intégrer des sources de mouvement hétérogènes afin de diversifier ses usages tout en garantissant leur interopérabilité. Ce stage avait pour objectif de concevoir, d'intégrer et de caractériser une nouvelle source de mouvement embarquée, puis d'en expérimenter l'utilisation dans CoMo.education, un projet de narration gestuelle et sonore destiné aux enfants de maternelle.

Une démarche progressive a été adoptée : prise en main du capteur inertiel LSM9DS1, acquisition et mise au format commun des données dans CoMo, comparaison avec les sources CoMote et R-IoT, optimisation temporelle, assemblage du dispositif, puis redéveloppement de l'application web. Le prototype réunit un Raspberry Pi Zero 2 W, le capteur, une batterie et un système de diffusion sonore. Il assure localement la captation du mouvement, la reconnaissance gestuelle et la production du son, tandis qu'une interface web permet de configurer l'interaction.

Une optimisation temporelle a permis d'obtenir une stabilité d'acquisition comparable à celle des autres sources utilisées dans CoMo. La comparaison des mesures inertielles a confirmé la cohérence globale des données produites, tout en mettant en évidence des écarts ponctuels importants entre les dispositifs. La nouvelle application simplifie la création des associations entre gestes et sons et permet l'importation de sons personnels.

Les résultats confirment la bonne intégration de cette source dans l'environnement CoMo. Dans le cadre de CoMo.education, un atelier d'évaluation conduit à envisager la réduction de l'encombrement du dispositif, la gestion de plusieurs histoires, des interfaces adaptées aux utilisateurs et une évaluation en atelier avec des enfants.

Remerciements

Je tiens tout d'abord à remercier chaleureusement Benjamin Matuszewski, pour son accompagnement tout au long de ces derniers mois. Ses conseils, sa disponibilité et les orientations qu'il m'a aidé à prendre ont été précieux dans la conduite de ce stage. Je le remercie également pour son regard attentif et son aide lors de la rédaction de ce rapport.

Je remercie également Frédéric Bevilacqua, responsable de l'équipe ISMM, pour son accueil au sein de l'équipe ainsi que pour les échanges que nous avons pu avoir autour du projet et des thématiques qui l'accompagnent.

Je souhaite remercier les chargées de médiation culturelle ainsi que l'ensemble des médiatrices et médiateurs impliqués dans CoMo.education. Leurs retours, nourris par leur connaissance du terrain et des enfants, ont largement contribué à faire évoluer le projet. Je les remercie également de m'avoir donné la possibilité d'assister à plusieurs ateliers, qui m'ont permis de mieux saisir le contexte et les difficultés du projet, mais aussi les enjeux humains et pédagogiques.

Mes remerciements s'adressent plus largement à l'ensemble des doctorantes, doctorants, chercheuses et chercheurs de l'équipe ISMM. Leur bienveillance, leur disponibilité et leur bonne humeur ont fait de ce stage une expérience particulièrement agréable, aussi bien sur le plan professionnel que personnel.

Je remercie enfin toutes les personnes rencontrées à l'Ircam avec lesquelles j'ai eu la chance d'échanger au cours de ce stage, que ce soit autour d'un projet, d'une question professionnelle ou simplement lors d'une conversation autour d'un café. Chacun de ces échanges m'a permis de découvrir de nouvelles perspectives et m'a rappelé toute la richesse de la recherche sur le son et la musique, qui me passionnent et me stimulent au quotidien.

Ce stage marquant également la fin du master, je souhaite profiter de ces quelques lignes pour remercier les responsables du Master Acoustique et Musicologie, parcours Ingénierie et Conception Sonore, Antoine Gonot et Mathieu Barthet, ainsi que l'ensemble des enseignantes, enseignants et intervenants qui nous ont transmis, au cours de ces deux années, de nombreuses connaissances théoriques et pratiques.

Comme les différents stages réalisés au cours de mes études, cette expérience m'a permis d'explorer des domaines du son dont je ne soupçonnais pas encore toute l'étendue. Elle marque toutefois une étape particulière, car les approches, les thématiques et les questionnements que j'y ai rencontrés sont ceux que je souhaite continuer à explorer et autour desquels j'aimerais construire la suite de mon parcours. Je remercie donc profondément toutes les personnes qui, de près ou de loin, ont contribué à la réalisation de ce stage et à la richesse de cette expérience.

Table des matières

1. Introduction et positionnement **1**
1.1 Contexte et enjeux 1
1.2 Problématique et objectifs 2

2. État de l'art et orientation du projet **4**
2.1 Méthodologies 4
2.2 Systèmes sonores connectés et distribués 5
2.2.1 Internet des Sons et technologies web 5
2.2.2 Les systèmes audio distribués 6
2.3 Systèmes interactifs et interaction son-mouvement 8
2.3.1 Le contrôle gestuel du son 9
2.3.2 La sonification du mouvement 10
2.4 Problématique et orientation du projet 11

3. Méthodologie et approche technique **15**
3.1 Démarche de résolution 15
3.2 Instrumentation et environnement 16
3.2.1 Environnement matériel et logiciel 16
3.2.2 Sources de mouvement et interopérabilité 18
3.2.3 Modèle probabiliste XMM 20
3.3 Méthodes d'évaluation du capteur de mouvement 22

4. Résultats et discussion **26**
4.1 Système interactif embarqué et caractérisation 26
4.1.1 Description du dispositif embarqué 26
4.1.2 Acquisition des données inertielles 28
4.1.3 Évaluation et optimisation 30
4.2 Nouvelle application web et système final 40
4.2.1 Cahier des charges 40
4.2.2 Description de l'application 41
4.2.3 Retours utilisateurs et travaux futurs 43
4.3 Discussion 46

5. Conclusion et perspectives **48**

Références bibliographiques **51**

Annexes **58**

1. Introduction et positionnement

1.1 Contexte et enjeux

L'introduction des réseaux informatiques dans les processus de travail, le développement de nouveaux protocoles de communication, l'arrivée d'Internet dans les années 1970 (un réseau informatique mondial accessible au public) et l'invention du Web (système hypertexte public fonctionnant sur Internet) dans les années 1990 ont permis le développement et la démocratisation de nouvelles technologies dans de nombreux secteurs (maisons et villes intelligentes, industrie, appareils portables, etc.).

Mark Weiser proposait déjà en 1991 le terme d'*ubiquitous computing* [1], pour exprimer l'idée que l'ordinateur du XXIe siècle ne serait pas un objet unique et central, mais un ensemble diffus de dispositifs interconnectés, intégrés aux lieux, aux objets et aux gestes, capables de fournir de l'information utile sans monopoliser l'attention (cf. Fig. 1). Dans ce contexte, la prolifération et l'utilisation de nouveaux types d'appareils comme les smartphones, les systèmes embarqués, ainsi que les nano-ordinateurs, ouvrent le champ de l'*Internet of Things* (IoT) [2, 3]. Ce paradigme permet aux objets d'interagir les uns avec les autres et de coopérer avec leurs voisins pour atteindre des objectifs communs [3]. Ces technologies ouvrent ainsi de nouvelles voies pour les chercheurs, développeurs, designers ou encore artistes, notamment dans les domaines liés à l'audio [4, 5] et à la musique [6, 7].

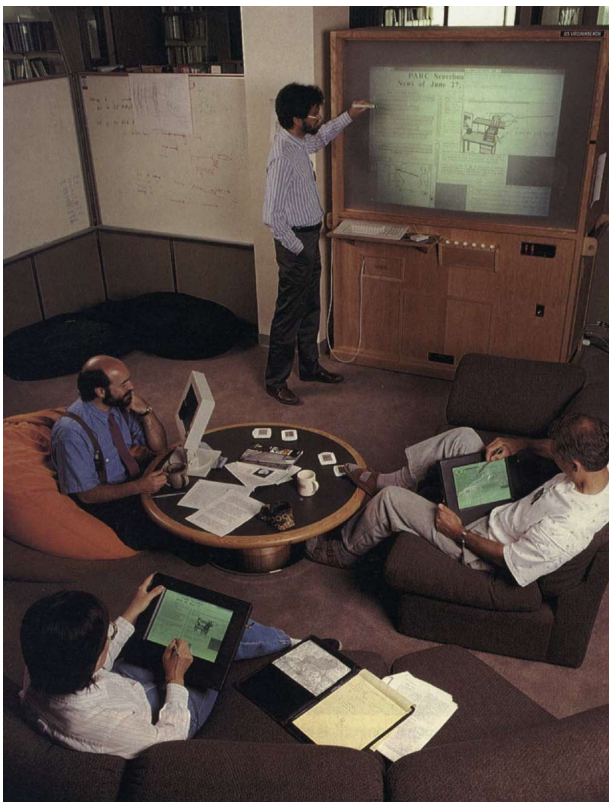


Figure 1: La vision utopique de Weiser sur l'*ubiquitous computing*. Des tableaux tactiles remplacent le tableau noir classique et communiquent avec les tablettes portables que les utilisateurs ont sur eux [1]

Plus récemment, les nouvelles avancées dans les technologies Web [4, 8], en particulier la spécification et le développement d'*Application Programming Interfaces* (API) telles que la *Web Audio API* [2], les *WebSocket* [3] ou le *WebGL* [4], ainsi que l'essor du langage de programmation *JavaScript* [5], ont permis d'envisager un environnement technique viable pour le développement et l'utilisation de dispositifs audio en réseaux [9]. Dans le milieu de la recherche, les communautés intéressées par le développement technique, pratique et artistique de ces technologies se réunissent lors de conférences telles que la *Web Audio Conference* [6] et le symposium international de l'IEEE sur l'Internet des Sons [7].

Dans ce contexte, les recherches sur le contrôle gestuel du son [10] et sur la sonification du mouvement [11] via l'intégration de capteurs ouvrent de nouvelles opportunités pour l'exploration d'interactions sonores et sociales synchronisées entre personnes, environnements, interfaces tangibles et sons spatialisés [4]. Les recherches dans ces domaines sont rapportées dans diverses communautés à travers des conférences comme *Sound and Music Computing* [8] (SMC), *New Interfaces for Musical Expression* [9] (NIME), *Movement and Computing* [10] (MoCo), *Computer Music Multidisciplinary Research* [11] (CMMR), ou encore la conférence CHI [12] de l'ACM (*Association for Computing Machinery*).

Au-delà des questions techniques qu'engendrent les objets sonores interactifs utilisant les technologies Web, la question de l'utilisation et de l'appropriation apparaît également centrale afin de définir, d'évaluer et de réviser les choix de conception selon les usages [6, 12]. Dans ce cadre, nous reprenons la définition de Dourish qui désigne « l'appropriation » comme étant « *the ways in which people adopt and adapt interactive technologies, fitting them into working practices and evolving those practices around them* » [13] [13].

1.2 Problématique et objectifs

Dans ce contexte général, les technologies Web ont ainsi permis de simplifier et de démocratiser l'utilisation des appareils mobiles (tels que les smartphones) dans la diffusion des sons, mais aussi dans la conception de systèmes gestuels interactifs. Cette dynamique s'inscrit dans l'essor de dispositifs permettant d'associer captation du mouvement, traitement en temps réel et génération sonore au sein d'environnements accessibles et relativement légers à déployer. Elle rejoint également le paradigme d'apprentissage automatique interactif (*interactive machine learning*, IML), notamment développé par Rebecca Fiebrink avec *Wekinator* [14] [14, 15], qui propose un environnement dans lequel l'utilisateur peut créer des exemples, entraîner un modèle, évaluer ses résultats et modifier itérativement les données ou les paramètres d'apprentissage, le tout en temps réel. Dans cette perspective, l'apprentissage n'est plus conçu comme une phase séparée,

[1] Source: M. Weiser, 1991 [1]
[2] https://www.w3.org/TR/webaudio/
[3] https://tools.ietf.org/html/rfc6455
[4] https://developer.mozilla.org/fr/docs/Web/API/WebGL_API
[5] https://developer.mozilla.org/fr/docs/Web/JavaScript
[6] https://wac-2025.ircam.fr/
[7] https://internetofsounds2026.ieee-internetofsounds.org/
[8] https://smc26.mbz.hr/
[9] https://nime.org/
[10] https://moco26.movementcomputing.org/
[11] https://cmmr2025.prism.cnrs.fr/
[12] https://dl.acm.org/conference/CHI
[13] « les manières dont les individus adoptent et adaptent les technologies interactives, les intègrent à leurs pratiques de travail et font évoluer ces pratiques autour d'elles » [traduction de l'auteur]
[14] https://doc.gold.ac.uk/~mas01rf/Wekinator/

opaque et exclusivement technique, mais comme un processus de conception interactif, pouvant être approprié par des artistes, musiciens ou concepteurs d'interaction, y compris sans expertise approfondie en apprentissage automatique [15].

L'environnement *CoMo* [12], développé par Benjamin Matuszewski à l'Ircam, propose un écosystème web permettant l'interaction gestuelle et sonore en utilisant les smartphones et les capteurs intégrés. Plus précisément, en s'appuyant sur la bibliothèque de reconnaissance gestuelle et d'apprentissage *XMM* développée par Jules Françoise, l'application permet à l'utilisateur d'enregistrer des gestes ou des postures, puis de les associer à une série de sons qui seront ensuite déclenchés lorsque les mouvements correspondants sont reconnus. Une telle approche présente un intérêt méthodologique important : elle permet de rapprocher la conception des interactions son–mouvement d'un processus de démonstration, d'exploration et d'ajustement progressif, dans lequel les relations entre geste et son ne sont pas entièrement définies à l'avance, mais peuvent être construites de manière itérative à partir de l'expérience de l'utilisateur.

Néanmoins, certaines limites ont pu être observées concernant l'utilisation des smartphones, notamment lors du projet CoMo.education [16], où les utilisateurs sont des enfants. D'une part, les fabricants de smartphones et leurs structures fermées rendent souvent fastidieux l'accès aux données des capteurs de mouvement, en raison de contraintes techniques ou de respect de la vie privée telles que l'usage de certificats. D'autre part, l'omniprésence des smartphones dans le quotidien peut entraver l'expérience proposée et disperser l'attention des enfants durant l'activité, du fait des multiples autres fonctions associées à cet objet, dont ils ont déjà connaissance et font usage. Dans ce contexte, l'utilisation conjointe de nano-ordinateurs, de capteurs dédiés et de haut-parleurs miniatures [4], constitue une alternative pertinente aux smartphones pour les usages dans lesquels ceux-ci deviennent une barrière ou un inconvénient. Il demeure toutefois important de préciser que les smartphones conservent une pertinence dans d'autres contextes en raison de leur diffusion massive, de leur écran et de leur facilité d'intégration dans des dispositifs collaboratifs et interactifs [17].

Dans cet effort de multiplication des solutions offertes aux utilisateurs et designers en fonction des contextes d'utilisation, sans prétendre à une hiérarchisation définitive de leur qualité, ce stage se concentre sur la réalisation et la caractérisation d'un prototype sonore embarqué interactif, muni d'un capteur de mouvement, d'un nano-ordinateur (Raspberry Pi) et de haut-parleurs miniatures, permettant, à l'aide d'outils logiciels adaptés, de diffuser du son localement en interaction avec les données de mouvement de l'utilisateur. Ce prototype a vocation à s'inscrire parmi les solutions techniques mobilisables dans l'écosystème *CoMo* [15]. Pour démontrer la pertinence du prototype dans un cadre d'utilisation réel, une part importante du stage porte sur le redéveloppement de l'application web associée au projet CoMo.education, afin de l'adapter aux besoins actuels et de permettre l'intégration du prototype interactif. Les missions du stage relèvent à la fois de l'ingénierie, par la nécessité de concevoir et d'intégrer un dispositif technique cohérent, et de la recherche appliquée, par l'attention portée à la littérature et aux perspectives d'usage du prototype.

[15] https://apps.ismm.ircam.fr/como

2. État de l'art et orientation du projet

2.1 Méthodologies

Le présent travail se situe à l'intersection des sciences du design, de l'interaction humain-machine et de la recherche en informatique musicale. Nigel Cross [18] distingue le design des sciences et des humanités par son orientation vers le monde artificiel et vers la construction de solutions adaptées à des problèmes souvent mal définis. Dans cette perspective, la conception ne relève pas uniquement de l'application de connaissances préexistantes : la réalisation d'un artefact peut elle-même contribuer à produire des connaissances. Findeli approfondit cette approche à travers la notion de recherche fondée sur des projets (*project-grounded research*), en distinguant le projet de design du projet de recherche. Le premier peut servir de terrain et d'opérateur au second, à condition que la démarche reste rigoureuse sur le plan scientifique et pertinente pour la pratique du design [19, 20]. Dans le cadre de ce stage, le prototype constitue ainsi à la fois une réalisation technique et un support d'investigation sur l'intégration de capteurs de mouvement dans un environnement web distribué.

Dans les environnements interdisciplinaires reposant sur des plateformes logicielles expérimentales, comme *CoMo*, les développements techniques peuvent également faire évoluer les questions de recherche. Matuszewski et Bevilacqua [21] distinguent à ce titre les postures complémentaires d'observation et de fabrication (observer/maker standpoints) : la première permet d'analyser les phénomènes étudiés, tandis que la seconde produit les artefacts à partir desquels de nouvelles observations deviennent possibles. Cette articulation rejoint la conception émergente de la recherche par la pratique décrite par Gaver et al. [22], dans laquelle les méthodes, les objectifs et les résultats peuvent se préciser au cours du projet. Le prototype n'est donc pas considéré comme l'application finale d'un programme entièrement défini à l'avance, mais comme un dispositif évolutif susceptible de faire apparaître de nouveaux problèmes et critères de conception.

Cette démarche accorde également une place importante à l'appropriation. Selon la théorie de la genèse instrumentale (*instrumental genesis theory*) présentée par Tchounikine [23], les utilisateurs transforment progressivement les artefacts en instruments au sein de leurs activités et poursuivent ainsi leur conception par l'usage. Cette perspective rejoint les principes de l'ingénierie de l'utilisabilité (*usability engineering*) formulés par Gould et Lewis [24] : prise en compte précoce des utilisateurs et de leurs tâches, observation empirique et conception itérative. Les prototypes doivent donc être confrontés aux usages afin d'être analysés et révisés à partir des réactions et difficultés observées sur le terrain. Ces retours et observations peuvent être étudiés qualitativement, par exemple grâce à une analyse thématique [25] visant à identifier les motifs récurrents relatifs à la compréhension, à l'appropriation et à la pertinence du dispositif. Ces principes structurent la démarche du stage, fondée sur le prototypage, l'évaluation et l'ajustement progressif des choix techniques et fonctionnels.

2.2 Systèmes sonores connectés et distribués

2.2.1 Internet des Sons et technologies web

L'Internet des objets (IoT) [2, 3] constitue le cadre général dans lequel s'inscrivent les recherches sur l'Internet des Sons. Il désigne l'extension d'Internet au monde physique par l'intermédiaire de capteurs, d'actionneurs, de téléphones mobiles ou de systèmes embarqués capables de communiquer et de coopérer à travers un réseau. Cette mise en relation des objets permet la circulation de données et la coordination de services, tout en soulevant des difficultés persistantes en matière d'interopérabilité, de sécurité, de protection de la vie privée et de gestion des ressources [3].

L'Internet des Sons (IoS) transpose ce paradigme au domaine sonore. Dans la définition proposée par Turchet et al. [5], l'IoS regroupe les objets sonores connectés, les infrastructures, les protocoles et les représentations permettant de produire, recevoir, analyser ou transmettre des informations liées au son. Le son y constitue simultanément un signal, une donnée, un médium d'interaction et un objet de calcul. L'IoS rassemble notamment l'*Internet of Musical Things* (IoMusT) [7], consacré aux dispositifs musicaux connectés, et l'*Internet of Audio Things* (IoAuT) [26], qui englobe plus largement les objets capables de produire, recevoir ou analyser de l'audio dans des environnements distribués.

Ces architectures permettent de relier musiciens, publics, ingénieurs du son et services numériques dans des interactions locales ou distantes [7, 27, 28, 29, 30]. Elles concernent également des usages non musicaux, tels que les réseaux acoustiques sans fil [31], les dispositifs de retour auditif liés au geste ou les technologies de santé. Les *smart sonic shoes*, par exemple, associent captation de la marche, sonification en temps réel et transmission des données afin d'accompagner certaines thérapies motrices [32, 33]. D'autres travaux mobilisent des textiles connectés pour associer gestes, calcul embarqué et ressources sonores en ligne [34]. Dans ces cas, le réseau ne transporte pas uniquement de l'audio : il articule capteurs corporels, sonification interactive [35], interfaces de supervision et services numériques.

Les technologies Web constituent aujourd'hui une base intéressante pour mettre en œuvre ces systèmes, notamment dans le contexte du *ubiquitous computing* [1, 4]. La Web Audio API permet la synthèse, le traitement, le routage, la spatialisation et l'analyse audio à partir d'une interface JavaScript normalisée par le World Wide Web Consortium (W3C) [36, 37]. Matuszewski et Rottier montrent que son usage peut dépasser le navigateur [38] et être étendu à des environnements tels que Node.js ou Rust [39], facilitant le partage de concepts et de composants entre interfaces web, serveurs et systèmes embarqués. Le protocole *WebSocket* [16] fournit quant à lui une communication bidirectionnelle en temps réel entre clients et serveur.

Le passage de l'IoT au *Web of Things* [40, 4] consiste ainsi à employer le Web comme couche applicative commune pour les objets connectés, afin d'améliorer leur interopérabilité et leur réutilisation. Ces technologies offrent une base accessible et portable pour faire communiquer des dispositifs hétérogènes. Elles ne répondent toutefois pas automatiquement à toutes les contraintes du temps réel sonore et ne fournissent pas une solution directement applicable à chaque cas d'usage. Dans le cadre de ce projet, elles justifient le choix d'une architecture web tout en faisant apparaître la nécessité d'un développement spécifique pour intégrer un dispositif embarqué geste-son à l'environnement CoMo.

[16] https://tools.ietf.org/html/rfc6455

2.2.2 Les systèmes audio distribués

Les systèmes audio distribués s'inscrivent dans une histoire antérieure au Web. Dès le début du XXe siècle, le Telharmonium permettait de transmettre des performances par le réseau téléphonique. Par la suite, différentes expérimentations ont utilisé les réseaux radiophoniques ou informatiques comme supports de création. Les travaux de la *League of Automatic Music Composers*, en 1978, constituent notamment l'un des premiers exemples documentés de musique informatique en réseau (*computer network music*) : plusieurs programmes y échangeaient des données et transformaient mutuellement leurs processus sonores [6, 9].

Une autre filiation concerne la spatialisation du son. L'Acousmonium du GRM reposait déjà sur une pluralité de haut-parleurs hétérogènes et sur une conception de la diffusion spatiale comme pratique de composition [9]. Les systèmes multicanaux sont longtemps restés liés à des infrastructures institutionnelles importantes, avant que les terminaux mobiles ne rendent envisageables des architectures distribuées à moindre coût [41]. À partir des années 1990, des projets comme *Global String* de Tanaka et Toeplitz, *FMOL* de Sergi Jordà, *Quintet.net* de Georg Hajdu ou *Auracle* ont ensuite fait du réseau un médium esthétique, un espace de création partagée ou un modèle d'organisation de l'interaction musicale [6].

Deux grandes configurations peuvent être distinguées. La performance musicale en réseau relie des musiciens géographiquement éloignés et impose des contraintes fortes de latence, de *jitter* et de synchronisation [30]. Les systèmes co-localisés réunissent au contraire les participants dans un même espace physique, tout en reliant leurs smartphones, ordinateurs, nano-ordinateurs ou capteurs par un réseau local [6]. Dans cette seconde configuration, particulièrement importante pour le projet étudié, le réseau structure des interactions collectives situées associant geste, diffusion sonore, visualisation et contrôle distribué [42, 43].

Le projet *Collective Sound Checks* [44] explorait déjà en 2015 les affordances sonores et sociales d'applications Web mobiles où les smartphones du public devenaient des unités de diffusion et d'interaction. *Collective Loops* [17] prolonge cette démarche en étudiant des interactions multimodales à partir de terminaux co-localisés, avec un rendu audiovisuel synchronisé fondé sur des standards Web (cf. Fig. 2). *Nü Soundworks* [45] propose quant à lui un environnement où les smartphones des spectateurs sont utilisés comme réseau distribué de haut-parleurs et de capteurs pendant la performance, avec un contrôle depuis une interface Max et un traitement audio dans les navigateurs via la Web Audio API. Ces projets montrent que la distribution ne concerne pas uniquement les sources sonores : elle transforme également les rôles et les formes de coopération entre les participants [44, 43].



Figure 2: *Collective Loops* lors des ateliers de l'Ircam Forum, Paris, 2015 [17]

Van Steen et Tanenbaum [46] proposent de définir un système distribué comme étant « *a collection of autonomous computing elements that appears to its users as a single coherent system* » [18]. Lorsqu'on transpose cette définition au sonore, on désigne par « systèmes audio distribués » ou « systèmes musicaux distribués » (*distributed music systems*) des ensembles de dispositifs hétérogènes interconnectés par un réseau, capables d'échanger des données et de produire, traiter ou diffuser du son [8, 6]. Dans le prolongement de la section suivante sur l'interaction son–mouvement, ces systèmes déplacent le problème du simple couplage geste–son vers celui de la coordination entre plusieurs machines, plusieurs sources sonores et plusieurs usagers, localement ou à distance. Le mouvement peut y rester central, mais il est alors pris dans une architecture plus large de synchronisation, de contrôle, de spatialisation et d'interaction collective [42, 16].

La période récente est marquée par le développement d'outils web adaptés à ces architectures. Le cadre le plus structurant ici est *Soundworks*, présenté par Matuszewski comme un framework dédié au prototypage et au développement d'applications multimédias distribuées reposant sur le Web [8, 47]. Son architecture repose généralement sur un serveur Node.js et sur des clients hétérogènes (navigateurs mobiles, ordinateurs de bureau, nano-ordinateurs) pouvant assurer la captation, le rendu sonore ou visuel et le contrôle. Le framework prend en charge les communications par WebSockets, la gestion d'états distribués ainsi qu'un système de plugins favorisant la modularité. Il permet ainsi de piloter un ensemble de dispositifs comme une entité cohérente malgré sa distribution physique.

Cette approche a notamment été développée dans le projet *DOTS* [19] (*Distributed Musical Things for Collective Interactions*) mené à l'Ircam, qui constitue un terrain de développement et de prototypage [48] pour les systèmes audio distribués co-localisés. L'intégration de réseaux de Raspberry Pi équipés pour l'audio a permis d'étudier le déploiement, le contrôle et

[17] Source: Site web du projet CoSiMa : https://cosima.ircam.fr/2015/11/25/collective-loops-forum-workshops/, et vidéo : https://vimeo.com/149649477?fl=pl&fe=vl

[18] « une collection d'éléments de calcul autonomes qui apparaît à ses utilisateurs comme un seul système cohérent. » [traduction de l'auteur]

[19] https://dots-project.ircam.fr/

l'appropriation artistique de tels systèmes [6]. La pièce *Quasimodots*, créée par Aliénor Golvet à partir d'un réseau de quarante nano-ordinateurs munis de microphones et de haut-parleurs, illustre cette orientation (cf. Fig. 3).



Figure 3: Installation pour la représentation de *Quasimodots* d'Aliénor Golvet, menée dans le cadre du projet *DOTS* à l'Ircam, Janvier - Mars 2024 [20]

L'environnement *CoMo* [12] s'inscrit également dans cette famille de systèmes co-localisés : un ordinateur assure l'infrastructure du réseau, les dispositifs mobiles transmettent des données inertielles, un modèle réalise la reconnaissance des gestes et les sons sont diffusés localement. Ce cas relie ainsi les systèmes distribués à une interaction son-mouvement collective conçue par itérations, co-design et *research through design*.

Ces travaux montrent le potentiel des architectures distribuées pour la création et la participation collective. Ils concernent cependant principalement des installations artistiques ou des environnements expérimentaux complexes. Les dispositifs simples, embarqués et reproductibles dans des contextes pédagogiques restent moins étudiés. Les travaux consacrés à des lecteurs dédiés pour les promenades sonores [49] montrent également l'intérêt de solutions autres que le smartphone lorsque l'on souhaite mieux maîtriser l'écoute, l'intégration matérielle et la cohérence du dispositif avec son contexte d'utilisation.

2.3 Systèmes interactifs et interaction son-mouvement

Les systèmes interactifs son-mouvement regroupent les dispositifs dans lesquels des mouvements corporels, instrumentaux ou gestuels sont captés et mis en relation avec une production ou un retour sonore. Ils concernent la musique, la danse et les installations, mais aussi la santé, le sport et le bien-être [50, 51, 52, 53, 54]. Ce domaine interdisciplinaire associe notamment informatique musicale, interaction humain-machine, sciences du mouvement, sonification et apprentissage automatique interactif [50, 55]. Il rassemble plusieurs traditions : contrôle gestuel des instruments numériques, sonification du mouvement, danse interactive, rééducation et médi-

[20] Source: Site web du projet DOTS : https://dots-project.ircam.fr/

ation [29, 56]. Ces systèmes interactifs soulèvent alors des questions relatives à leur conception et à la manière dont les utilisateurs peuvent les contrôler, car ici, le mouvement n'est pas seulement une commande : il devient la condition même de l'expressivité de l'outil.

Les travaux sur l'*embodied musical interaction* [57], comme ceux d'Atau Tanaka (cf. Fig. 4) montrent également que l'interaction geste-son ne se limite pas à une commande instrumentale. L'utilisation de capteurs corporels ou biophysiques (EMG) permet d'envisager des relations perceptives et situées dans lesquelles le corps participe pleinement à la construction de l'expérience sonore. Dans tous ces cas, le geste ne constitue pas seulement une commande : il contribue à l'expressivité et à la compréhension de l'outil.



Figure 4: Atau Tanaka jouant d'un instrument EMG lors d'un concert, en 2017 [21]

2.3.1 Le contrôle gestuel du son

La musique et les arts de la scène constituent le terrain historique du contrôle gestuel du son. Du Thérémine aux instruments numériques et augmentés, de nombreux dispositifs ont cherché à utiliser le corps ou le geste comme médiateurs de la synthèse sonore [58]. À partir des années 1990, les recherches sur les instruments de musique numériques (*digital musical instruments*), la danse interactive et les performances multimédias ont développé des relations plus complexes entre mouvement, captation et production sonore [29, 58].

Les technologies de captation employées comprennent les caméras, les unités de mesure inertielle (IMU) associant accéléromètres, gyroscopes et magnétomètres [58], les capteurs de flexion ou de force [59] et les capteurs biophysiques [60]. Les IMU sont particulièrement adaptées aux interfaces légères et portables, mais leur utilisation impose des contraintes de fréquence d'échantillonnage, de latence, d'autonomie et de programmation. Des dispositifs tels que Pipo

[21] Source: A. Tanaka, 2019 [57]

Motion [22], Mi.Mu Gloves [23], R-IoT [24] ou SOMI-1 [25], illustrent cette évolution vers des interfaces configurables destinées au contrôle sonore ou musical [58]. Les smartphones occupent également une place importante depuis plus de vingt ans, en raison de leurs capteurs intégrés et de leur large diffusion [61].

Ces interactions sont aussi mobilisées dans l'éducation et la médiation. Duarte-García et al. [62] décrivent par exemple un système musical interactif fondé sur une application Android et une interface Max/MSP, employé lors d'ateliers d'électroacoustique avec des enfants. Le geste y devient un moyen d'explorer le sonore et de s'approprier un univers musical. Cette démarche rejoint le *Sonic Interaction Design* (SID), qui étudie non seulement l'efficacité du contrôle, mais aussi la manière dont les relations entre action et son deviennent signifiantes, culturellement situées et expérientielles [63, 64].

La diversité des dispositifs et des relations geste-son explique le recours fréquent à des environnements favorisant le prototypage rapide, tels que Max/MSP [26], Pure Data [27] ou SuperCollider [28], ainsi qu'à des outils spécialisés comme Wekinator [29], le Gestural Sound Toolkit [30] [65] ou MuBu [31]. Ces environnements permettent de construire des « mappings », c'est-à-dire des relations entre les données de mouvement et les paramètres du son.

Un « mapping explicite » est défini manuellement par des règles reliant les variables d'entrée aux paramètres sonores. Dans un « mapping implicite », la relation peut être médiée par des traitements, des états ou des modèles appris à partir d'exemples. Les techniques d'apprentissage automatique (machine learning) peuvent être utilisées afin de définir des correspondances à partir d'exemples enregistrés [66, 67], notamment pour la classification de gestes ou pour l'établissement de mappings par régression. Cette dernière approche, souvent dite *user-centered* ou *interactive* [66], occupe une place centrale dans notre travail, puisque le système repose précisément sur un apprentissage à partir d'exemples de mouvements.

2.3.2 La sonification du mouvement

La sonification consiste à transformer des données en relations sonores perceptibles afin d'en faciliter la communication ou l'interprétation [68, 69]. Elle devient interactive lorsque le son s'inscrit dans une boucle continue entre l'utilisateur et le système et fournit des informations utiles à l'activité en cours [70]. Appliquée au mouvement, cette approche conduit à la notion de sonification du mouvement, définie par Effenberg comme un « concept de mapping des paramètres de mouvement en son créant de nouveaux flux perceptifs congruents avec l'évolution temporelle des paramètres cinématiques ou dynamiques » [71, 56]. Il convient toutefois de distinguer les tâches orientées vers le son, dans lesquelles le geste contrôle explicitement une production sonore, des tâches orientées vers le mouvement, dans lesquelles le retour auditif sert à guider, apprendre ou corriger l'action [50]. Les mêmes technologies de captation et de synthèse peuvent ainsi répondre à des objectifs différents : expressivité musicale, apprentissage,

[22] https://pipointerfaces.com/
[23] https://mimugloves.com/
[24] https://github.com/ircam-ismm/riot-v3
[25] https://instrumentsofthings.com/products/somi-1
[26] https://cycling74.com/
[27] https://puredata.info/
[28] https://supercollider.github.io/
[29] https://docubase.mit.edu/tools/wekinator/
[30] https://ircam-ismm.github.io/max-msp/gst.html
[31] https://forum.ircam.fr/projects/detail/mubu/

motivation, compensation sensorielle ou correction du geste.

La sonification du mouvement est également étudiée dans la rééducation et l'apprentissage sensori-moteur. Un retour sonore continu peut fournir des informations sur l'action réalisée et soutenir la perception ou le contrôle moteur [50, 56]. Dans le sport et la rééducation, ses effets restent cependant dépendants des tâches, des mappings et des profils d'utilisateurs [72]. Des dispositifs comme SoniBand [73] montrent également que le retour sonore peut modifier le ressenti corporel, l'engagement et certains comportements moteurs [74]. Le son ne constitue donc pas uniquement un retour informatif : il participe à la représentation et à l'expérience du mouvement.

La littérature établit ainsi la possibilité de relier mouvement et son dans de nombreux contextes. Elle montre cependant que la diversité des technologies de captation, des stratégies de mapping et des usages limite la transposition directe d'un dispositif à un autre. Dans ce stage, le principal enjeu ne réside donc pas dans la démonstration générale de cette relation, mais dans la conception d'un dispositif embarqué, suffisamment robuste et léger, compatible avec un environnement web existant et adapté à un contexte pédagogique collectif.

2.4 Problématique et orientation du projet

Problématique. Un enjeu important des systèmes interactifs fondés sur le mouvement concerne l'interopérabilité des dispositifs de captation. La multiplication des sources permet en effet d'envisager de nouvelles configurations et de nouveaux usages, à condition que leurs données puissent être exploitées indépendamment du matériel employé. Cet enjeu est central pour *CoMo* [12], un framework web destiné à la conception d'interactions gestuelles et sonores, initialement développé autour des smartphones. Son évolution suppose de pouvoir intégrer des sources hétérogènes au moyen d'une représentation commune, afin de les rendre aussi transparentes que possible pour les applications. Le stage s'inscrit dans cette dynamique par la conception et l'intégration d'une nouvelle source de mouvement compatible avec CoMo.

Plusieurs projets (cf. Fig. 5) illustrent les usages de ce framework : narration sonore avec *CoMo.education* [32], apprentissage de la direction de chœur avec *CoMo Vox* [33], rééducation avec *CoMo-Rehabilitation* [34] ou exploration des relations entre geste et son avec *CoMo Elements* [35].

[32] https://www.premierscris.org/como-education
[33] https://apps.ismm.ircam.fr/comovox
[34] https://www.stms-lab.fr/projects/pages/sonification-du-mouvement-pour-la-reeducation
[35] https://apps.ismm.ircam.fr/como-elements



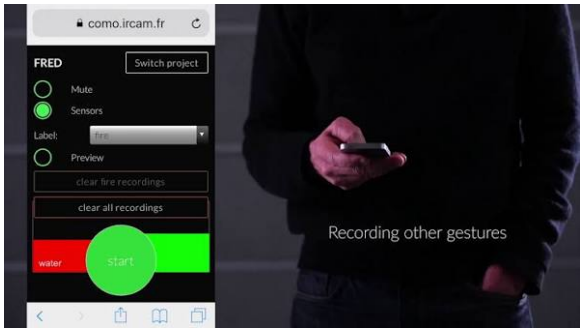
(a) Atelier CoMo.education dans une classe [36]



(b) Application web CoMo Vox [37]



(c) Dispositif de CoMo-Rehabilitation [38]



(d) Tutoriel de CoMo Elements [39]

Figure 5: Différents projets interactifs développés avec le framework CoMo

Dans le cadre du stage, *CoMo.education* a été retenu comme cas d'usage pour intégrer et expérimenter la nouvelle source. Inspirée des pédagogies actives de Maria Montessori et de John Dewey, cette application accompagne les pratiques de narration en maternelle. L'enseignant et les enfants jouent et sonifient collectivement certaines parties d'une histoire imaginée, en les interprétant par des gestes [16]. Un système de reconnaissance (utilisant la bibliothèque *XMM* [75]) associe les mouvements captés par les capteurs inertiels du smartphone (cf. Fig. 6) à des sons spécifiques, ensuite diffusés par le même appareil. Cette forme de narration sonore vise à mobiliser le corps entier et à favoriser les interactions kinesthésiques et collectives (cf. Fig. 7). Elle présente de nombreux bénéfices pour le développement des enfants, notamment l'exploration de l'environnement, le développement de la créativité et des compétences sociales ainsi que la mobilisation des compétences cognitives.

[36] Source: Voillot et al., 2024 [16]
[37] Source: Site web équipe ISMM, Ircam [https://apps.ismm.ircam.fr/comovox]
[38] Source: Site web équipe ISMM, Ircam [https://www.stms-lab.fr/projects/pages/sonification-du-mouvement-pour-la-reeducation]
[39] Source: Site web équipe ISMM, Ircam [https://apps.ismm.ircam.fr/como]

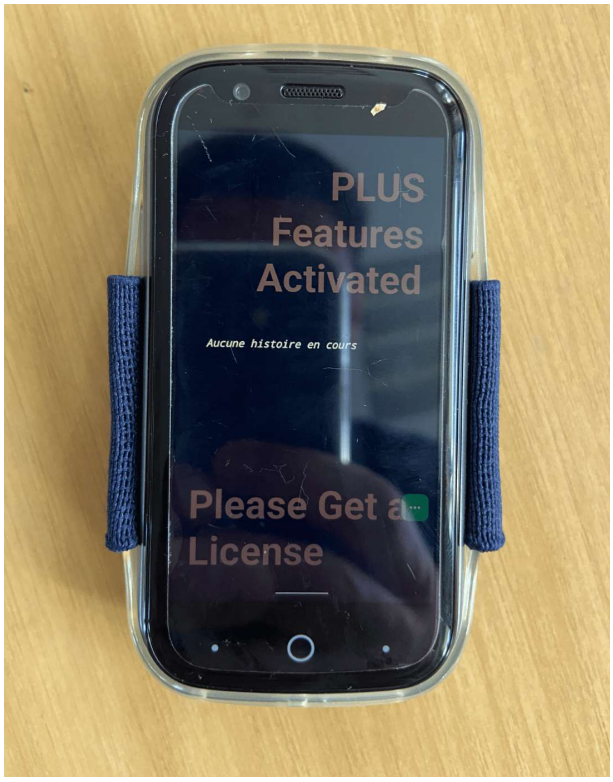


Figure 6: Petit smartphone utilisé par les enfants lors de l'atelier CoMo.education



Figure 7: Scénario des histoires interactives de CoMo.education, mobilisant la communication, la compréhension et la mémorisation d'un récit narratif, mais aussi l'écoute et l'attention sonores, la coordination gestuelle et la conscience corporelle ou encore l'utilisation et la démystification d'un outil numérique : le smartphone. [40]

Bien que l'utilisation des smartphones offre des avantages évidents en matière de popularité, de diffusion et d'intégration de capteurs embarqués, leur emploi dans ce projet pédagogique qui implique de jeunes enfants pose problème. D'une part, le smartphone est un objet fortement associé à des usages quotidiens de divertissement, de communication ou de consommation numérique. D'après les observations faites par les animateurs et par l'auteur lors de plusieurs ateliers pédagogiques, sa présence détourne régulièrement l'attention des enfants et perturbe l'intention pédagogique initiale. D'autre part, l'écran lui-même, bien que désactivé durant l'activité, tend à focaliser l'interaction sur une logique de consultation ou de manipulation visuelle, alors même que le projet CoMo.education cherche à valoriser une approche plus incarnée, collective et située du récit et de l'interaction geste-son. À cela s'ajoutent des contraintes plus techniques : l'accès aux capteurs de mouvement intégrés dépend des politiques imposées par les fabricants et les systèmes d'exploitation, ce qui peut rendre leur exploitation plus lourde ou moins flexible.

Ces difficultés ont notamment conduit Voillot et al. [16] à envisager la construction de dispositifs dédiés réunissant capteurs de mouvement, capacité de traitement, batterie et haut-parleurs, notamment à partir de nano-ordinateurs tels que les Raspberry Pi. À l'échelle de CoMo, Saint-Cast et al. [12] mentionnent également l'intégration d'IMU sans fil et la possibilité de remplacer les haut-parleurs des smartphones par des systèmes embarqués. Ces travaux établissent donc directement la pertinence d'une alternative matérielle, sans pour autant remettre en cause l'intérêt du smartphone dans d'autres configurations.

Orientation. Le projet s'inscrit dans ces différentes perspectives par la conception d'un dispositif interactif regroupant un capteur de mouvement, un nano-ordinateur, une batterie, une carte son et des haut-parleurs, ainsi que par son intégration dans le cas d'usage réel de CoMo.education. Le premier axe du stage relève ainsi de l'ingénierie et concerne l'acquisition, la mise au format et l'intégration des données d'un nouveau capteur dans un système embarqué et distribué. Le second axe porte sur son intégration dans l'application CoMo.education et permet son expérimentation dans une démarche de conception itérative. Enfin, l'intégration du prototype au framework CoMo pourra plus généralement permettre de l'utiliser au-delà du seul cas de CoMo.education, par exemple dans des contextes de rééducation, de création artistique ou d'expérimentation scientifique.

[40]Source : Site web Premier Cris [https://www.premierscris.org/como-education]

3. Méthodologie et approche technique

3.1 Démarche de résolution

Le projet a été conduit selon une démarche progressive et incrémentale, structurée en plusieurs étapes successives. Cette organisation visait à maîtriser la complexité du développement et à valider séparément chaque composant avant son intégration dans le système interactif final. Elle a également permis d'identifier plus facilement l'origine d'éventuels dysfonctionnements et d'apporter les ajustements nécessaires au cours de la conception.

La première étape a consisté à prendre en main le nouveau capteur de mouvement au moyen d'un unique programme (en dehors de CoMo), pour assurer la récupération des données brutes. Cette acquisition a ensuite été intégrée à l'environnement web CoMo et adaptée afin de permettre la compatibilité du capteur avec l'architecture existante et le format de données employé (cf. Section 3.2.2). Le capteur a ensuite été caractérisé et comparé aux sources de mouvement déjà compatibles avec CoMo, avant d'engager un travail d'optimisation de l'acquisition des données. Une fois cette chaîne de traitement stabilisée, les différents composants matériels ont été réunis au sein d'un dispositif embarqué. À l'issue de ces étapes, le dispositif reposait sur une base de fonctionnement suffisamment générique pour permettre son intégration dans différents projets développés au sein de l'environnement web.

La dernière étape a consisté à préciser son usage dans le contexte de CoMo.education, en redéveloppant l'application web afin d'y permettre l'utilisation du nouveau dispositif et de répondre aux besoins actuels du projet, tout en assurant la compatibilité avec les évolutions en cours de l'environnement CoMo. Pour le développement de la nouvelle application, l'identification des besoins et des fonctionnalités majeures s'est appuyée sur la version précédente (cf. Fig. 8), tout en intégrant au mieux les nouveaux besoins exprimés par les utilisateurs en début de stage. La nouvelle version présentée dans ce rapport a ainsi été redéveloppée intégralement, sans réutilisation directe du code antérieur.

La démarche mise en œuvre durant ce stage repose donc sur une approche de prototypage et de validation progressive, visant à sécuriser l'intégration des données de mouvement dans un environnement web distribué dédié à l'interaction geste-son. Le choix de cette méthode se justifie par la nature du système et par les outils utilisés, qui articulent plusieurs couches hétérogènes (cf. Section 4.1.1), dont l'intégration doit être testée et validée de manière modulaire avant toute montée en complexité.

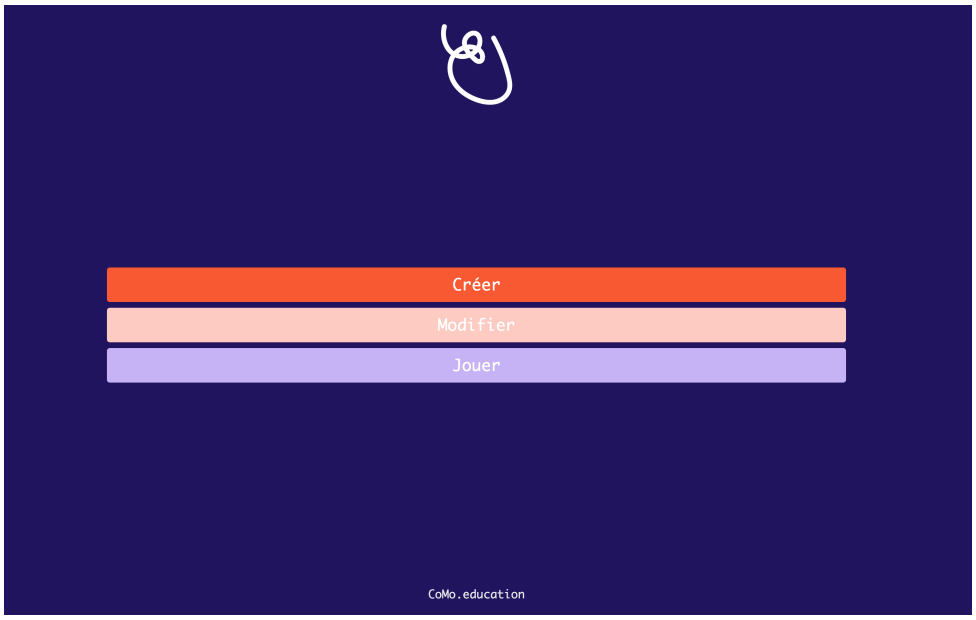


Figure 8: Page d'accueil et interface du client web *teacher* de l'ancienne version de l'application CoMo.education

3.2 Instrumentation et environnement

3.2.1 Environnement matériel et logiciel

Le projet présenté dans ce rapport s'appuie sur plusieurs couches matérielles et logicielles issues de travaux consacrés aux systèmes musicaux distribués et à leur mise en œuvre au moyen des technologies web [9]. Nous mobilisons notamment le framework *Soundworks* [8, 47] pour la communication et la synchronisation de clients hétérogènes ainsi qu'un ensemble d'outils et de bibliothèques soutenant le prototypage rapide [48] et le développement d'une large gamme d'applications audio et musicales [76]. Dans cette perspective et afin de construire un dispositif qui soit adaptable et résistant aux rapides évolutions logicielles et matérielles, nous nous reposons sur des technologies Web normalisées par le World Wide Web Consortium (W3C) et sur l'environnement d'exécution JavaScript *Node.js* [41].

Dans le cadre d'un système audio distribué et interactif (ici geste-son), la couche matérielle peut être décrite à partir de plusieurs composantes principales. La première est l'unité de calcul, qui peut prendre la forme d'un ordinateur ou d'un nano-ordinateur, et qui assure l'exécution de l'application, le traitement des données issues du capteur ainsi que la communication avec l'écosystème logiciel. La deuxième composante est le dispositif de captation du mouvement, chargé de mesurer les gestes ou postures de l'utilisateur à l'aide d'un capteur inertiel (dédié ou intégré). Ce dispositif regroupe généralement un accéléromètre, un gyroscope et un magnétomètre, chacun mesurant trois axes. Ces mesures constituent l'entrée principale du système interactif. La troisième composante correspond au système de diffusion audio, c'est-à-dire aux haut-parleurs ou à tout autre système de diffusion permettant de rendre audible la réponse sonore produite par le système.

[41] https://nodejs.org/en

La couche applicative s'appuie donc sur *Soundworks* [42], un framework conçu pour le développement d'applications distribuées temps réel basées sur les technologies web. Cet environnement prend en charge à la fois l'exécution de clients navigateur (destinés aux interfaces) et de clients Node.js, combinée à des communications en temps réel via *WebSockets* [43] et à un mécanisme de synchronisation d'états partagés ; ce qui permet de concevoir des systèmes distribués pouvant notamment être déployés sur un Raspberry Pi (cf. Fig. 9). Basé sur soundworks, *CoMo* [44] est quant à lui défini comme un framework pour l'interaction entre gestes, mouvements et sons, ce qui inscrit le prototype dans un environnement dédié à son usage. Nous utilisons également les outils (plugins) provenant de *Soundworks*, comme celui qui permet d'enregistrer des données arbitraires [45] et celui qui permet de surveiller des répertoires puis de mettre à jour leur contenu [46]. Plus globalement, nous mobilisons les utilitaires JavaScript développés à l'Ircam comme *sc-utils* [47], *sc-motion* [48] et *sc-signal* [49], qui fournissent un ensemble d'outils réutilisables pour la manipulation de flux de données, l'analyse du mouvement et le traitement de signaux dans des environnements interactifs en temps réel. Le moteur audio est fourni par la bibliothèque « node-web-audio-api » qui implémente l'API Web Audio pour l'environnement Node.js à l'aide du langage de programmation Rust [38, 39]. Enfin, les différents éléments matériels s'inscrivent dans une mise en réseau qui forme une chaîne cohérente dans laquelle le mouvement est capté, traité, puis transformé en retour sonore dans un environnement interactif et distribué.

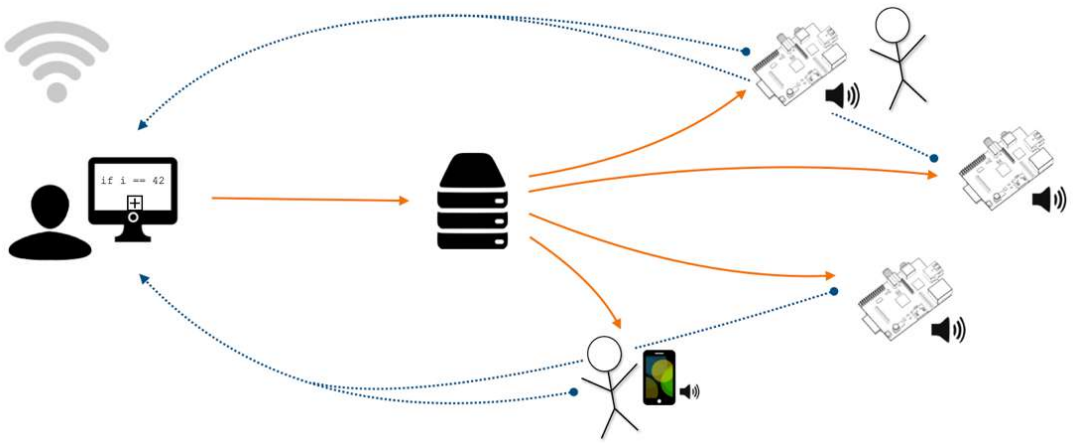


Figure 9: Architecture distribuée du framework Soundworks : échanges d'informations entre le serveur central, l'interface web de contrôle et les clients embarqués connectés au réseau Wi-Fi local. (Source : B. Matuszewski)

Afin de permettre la rapidité d'itération, le déploiement sur Raspberry Pi est facilité par l'écosystème *dotpi* [50], spécifiquement conçu pour configurer, déployer, exécuter et superviser des applications audio distribuées sur des Raspberry Pi. Ce gestionnaire permet en particulier la synchronisation des projets, leur exécution distante et leur supervision, ce qui en a fait un outil pratique pour les phases de test et de prototypage.

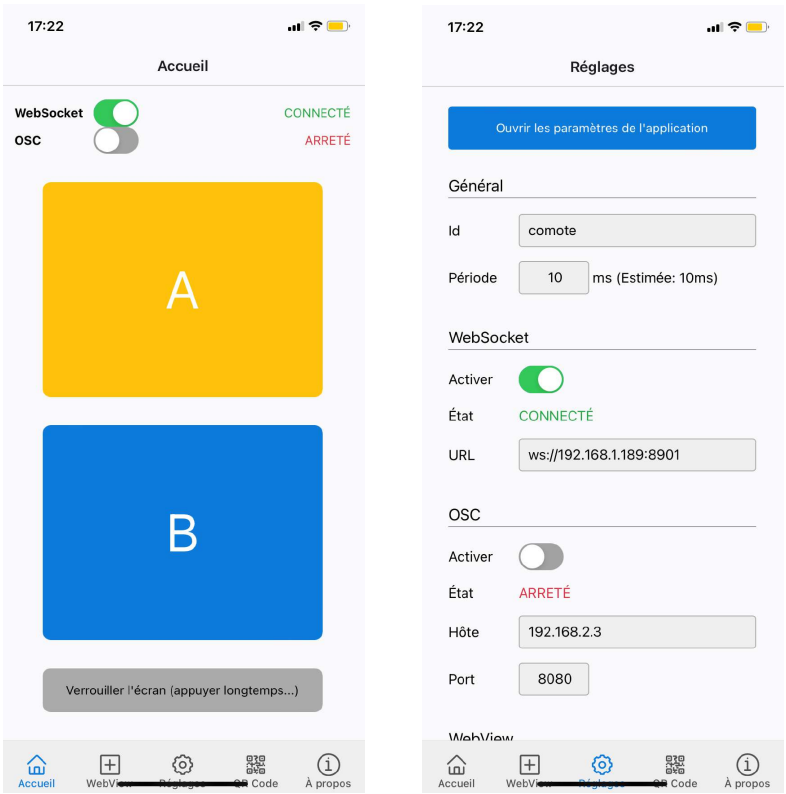
[42] https://soundworks.dev/
[43] https://tools.ietf.org/html/rfc6455
[44] https://ircam-ismm.github.io/como/
[45] https://soundworks.dev/plugins/logger.html
[46] https://soundworks.dev/plugins/filesystem.html
[47] https://github.com/ircam-ismm/sc-utils
[48] https://github.com/ircam-ismm/sc-motion/
[49] https://github.com/ircam-ismm/sc-signal
[50] https://ircam-ismm.github.io/dotpi/

La partie logicielle du projet est développée en JavaScript pour le côté fonctionnel (backend) et en HTML/CSS pour le côté interface (frontend). L'analyse des données est réalisée en Python, en utilisant notamment les bibliothèques *pandas* [51], *NumPy* [52] et *Matplotlib* [53].

3.2.2 Sources de mouvement et interopérabilité

Sources de mouvement. Avant ce stage, les sources de mouvement pouvant être utilisées dans l'environnement CoMo étaient l'application mobile *CoMote* et le capteur *R-IoT* :

- *CoMote* [54] est une application mobile (cf. Fig. 10) développée par l'équipe ISMM de l'Ircam, qui permet de transformer un smartphone en source de mouvement. Elle exploite directement les capteurs inertiels intégrés au téléphone, c'est-à-dire l'accéléromètre, le gyroscope et le magnétomètre. Contrairement à un capteur matériel dédié, CoMote ne nécessite donc aucun dispositif électronique supplémentaire, ce qui facilite considérablement son déploiement dans des contextes de démonstration, de médiation ou d'expérimentation. Les données sont ensuite transmises en temps réel à l'environnement logiciel via les protocoles OSC ou WebSocket, selon le contexte d'utilisation. L'un des principaux intérêts de CoMote réside dans son accessibilité et sa simplicité d'utilisation. En contrepartie, les performances dépendent directement du smartphone utilisé, notamment de la qualité des capteurs inertiels et du système d'exploitation, qui peuvent engendrer des variations selon les appareils.



(a) Page d'accueil (b) Page des réglages

Figure 10: Captures d'écran de l'application mobile CoMote

[51] https://pandas.pydata.org/
[52] https://numpy.org/
[53] https://matplotlib.org/
[54] https://apps.ismm.ircam.fr/comote

- Conçu par Emmanuel Fléty [77], le *R-IoT* constitue, de son côté, une source de mouvement spécifiquement conçue pour les applications interactives en temps réel. Contrairement à CoMote, il ne repose pas sur un smartphone mais sur une carte électronique (cf. Fig. 11) intégrant directement une centrale inertielle (IMU), un microcontrôleur ainsi qu'une interface de communication réseau. Cette architecture lui permet d'acquérir les mesures inertielles, de les traiter localement puis de les transmettre via un réseau Wi-Fi, principalement à l'aide du protocole OSC. Accompagné d'une batterie, le R-IoT constitue une solution matérielle compacte (34×18 mm), sans fil et robuste, utilisée pour de nombreuses expérimentations menées au sein de l'équipe ISMM.



Figure 11: Capteur IMU R-IoT Wi-Fi/OSC (version 3)

Afin de synthétiser les principaux apports et limites des solutions compatibles avec l'environnement CoMo, nous proposons une comparaison ciblée dans le tableau ci-dessous (cf. Tableau 1). Ce tableau ne vise pas à établir une hiérarchie générale entre les approches existantes, mais à mettre en évidence leur pertinence relative selon plusieurs critères directement liés à notre problématique. Cette mise en regard permet ainsi de faire apparaître plus clairement les compromis associés à chaque solution et de justifier l'orientation retenue pour le projet.

Solution	**Atouts majeurs**	**Limites majeures**	**Pertinence**
CoMote / Smartphone	- Disponibilité - Intègre des capteurs, un écran et des haut-parleurs	- Contraintes d'accès au capteur - Source de distraction, notamment chez les enfants	- Configuration collaborative et/ou interactive, mais limitée dans le cadre de CoMo.education
R-IoT	- Légèreté et petite taille - Robustesse - Connexion Wi-Fi et transmission de messages OSC	- Absence de diffusion sonore - Nécessite un ordinateur pour traiter les données	- Captation gestuelle sans fil
Nano-ordinateur avec IMU et haut-parleurs intégrés	- Dispositif interactif complet et autonome - Système dédié, sans autre fonctionnalité	- Dispositif à concevoir et à caractériser - Nécessité d'assurer sa compatibilité avec l'environnement CoMo - Nécessité d'être compatible avec une utilisation par des enfants	- Alternative aux smartphones, ne comportant pas d'écran

Tableau 1: Synthèse comparative des dispositifs actuellement compatibles avec l'environnement CoMo

Interopérabilité. Dédié à la création d'applications distribuées pour l'interaction mouvement-son, l'architecture logicielle de CoMo permet à des sources hétérogènes d'être manipulées dans l'application selon une logique commune et interopérable. En effet, les différents capteurs de mouvement se distinguent généralement par leur conception matérielle, leur protocole de communication, leur fréquence d'échantillonnage, leur précision, leur latence et/ou leur environnement d'exécution. Bien que certaines différences ne puissent être complètement abstraites, un certain degré d'interopérabilité est pourtant possible. Ainsi, du point de vue de l'application, différents capteurs/appareils peuvent être considérés comme des « sources de mouvement » transparentes, notamment en unifiant leurs données dans un format commun. L'interopérabilité repose alors sur l'abstraction des sources de mouvement et l'unification du format des données en dressant une structure commune, avec des grandeurs physiques identifiées, des axes explicites et des informations temporelles [55].

Ce principe trouve une application concrète dans l'environnement CoMo, où les données provenant du R-IoT et de CoMote suivent une représentation commune, qui se base sur différentes spécifications du W3C [56] et qui garantit leur transparence dans l'environnement web. Ce format commun agit comme une interface qui rend possible, comme dans notre cas, l'ajout d'une nouvelle source sans modifier profondément l'architecture logicielle, mais également la comparaison de plusieurs capteurs dans des conditions similaires, ou encore la substitution transparente d'une source à une autre. Dans un cas d'usage, les sources peuvent alors être échangées ou combinées, ce qui permet d'envisager différentes configurations dans un projet.

Le format (v3) des données de mouvement propose une représentation structurée aux formats JSON ou OSC, organisée autour d'une *frame* contenant plusieurs sous-ensembles de données. En fonction des données physiques recueillies par le capteur, une frame peut contenir des grandeurs telles que l'accélération, la vitesse angulaire, le champ magnétique ou encore une estimation de la gravité. Chacune de ces données est représentée par trois composantes spatiales, correspondant aux axes X, Y et Z, et est associée à des informations temporelles : horodatage et fréquence d'échantillonnage. Cette organisation permet d'exposer à la fois la structure physique des mesures et les métadonnées nécessaires à leur interprétation temporelle. Nous pouvons également mentionner que l'acquisition des frames est indépendante de l'usage qui est décidé dans l'application (ex. : apprentissage, reconnaissance ou contrôle sonore).

3.2.3 Modèle probabiliste XMM

La reconnaissance gestuelle mise en œuvre dans le système repose sur *XMM* [57], une bibliothèque d'apprentissage automatique destinée à la modélisation de données temporelles et multimodales. Son utilisation s'inscrit dans une démarche d'apprentissage automatique interactif, également désignée en anglais par *Interactive Machine Learning* [78, 79], dans laquelle l'utilisateur participe directement à la constitution du jeu de données en réalisant lui-même des exemples à reconnaître. Après une première phase d'apprentissage, le modèle peut être testé immédiatement, puis ajusté en ajoutant, supprimant ou réenregistrant certains exemples. Cette alternance entre apprentissage et expérimentation permet de construire progressivement un vocabulaire gestuel sans nécessiter une base de données constituée au préalable [67].

XMM ne désigne pas un modèle unique, mais une bibliothèque proposant plusieurs modèles probabilistes adaptés à différents types de données. Elle comprend notamment les modèles

[55] https://ircam-ismm.github.io/como/format/v3.html
[56] https://www.w3.org/TR/generic-sensor/
[57] https://github.com/ircam-ismm/xmm

de mélanges gaussiens, ou GMM, adaptés à la classification d'observations instantanées, ainsi que les modèles de Markov cachés hiérarchiques, ou HHMM, destinés à la reconnaissance de gestes possédant une évolution temporelle. *XMM* propose également des modèles multimodaux capables d'apprendre une relation entre des paramètres de mouvement et des paramètres sonores [80, 81]. Dans le système présenté dans ce rapport, la reconnaissance repose sur un HHMM : le modèle apprend la structure temporelle des gestes, tandis que l'association entre une classe gestuelle et un son est définie séparément dans l'application.

Constitution du jeu d'apprentissage. L'apprentissage est supervisé : chaque exemple enregistré est associé à une étiquette correspondant au nom du geste. Un exemple n'est pas constitué d'une seule mesure, mais d'une séquence de trames successives décrivant le mouvement pendant toute la durée de l'enregistrement. Chaque trame contient un vecteur de caractéristiques extrait des données du capteur. Dans le prototype développé, ce vecteur comporte dix valeurs : les trois composantes de l'accélération, les trois composantes de la vitesse angulaire, les trois composantes de l'estimation de la gravité et une valeur scalaire représentant l'intensité du mouvement. Ces caractéristiques sont à la fois employées pour l'apprentissage et pour la reconnaissance.

Modélisation temporelle des gestes. Un modèle de Markov caché représente un geste comme une succession d'états internes qui ne sont pas directement observés. Ces états peuvent être interprétés comme différentes phases du mouvement, par exemple son amorce, son développement et sa terminaison. Le modèle apprend à la fois les caractéristiques généralement observées dans chacune de ces phases et les probabilités de transition d'une phase vers une autre [80].

Les données associées à chaque état sont représentées par une distribution de probabilité, généralement une distribution gaussienne multidimensionnelle. Celle-ci est principalement caractérisée par une moyenne et une covariance. La moyenne représente les valeurs typiques des données de mouvement dans l'état considéré. La covariance décrit leur variabilité ainsi que les relations entre les différentes composantes du vecteur. Le modèle ne mémorise donc pas simplement un geste de référence : il construit une représentation statistique qui peut tolérer certaines différences entre plusieurs réalisations du même mouvement [80].

L'organisation temporelle permet également de distinguer des gestes caractérisés par des valeurs similaires, mais réalisés dans un ordre différent. Par exemple, deux mouvements peuvent mobiliser des accélérations comparables tout en possédant des dynamiques opposées. Contrairement à un modèle instantané, le HHMM prend en compte la succession des trames et la progression du geste. L'enregistrement de plusieurs exemples permet de représenter les variations possibles d'un même geste, notamment en matière de vitesse, d'amplitude ou d'orientation. Toutefois, le modèle ne peut généraliser qu'à partir de la variabilité présente dans le jeu d'apprentissage. Avec un nombre limité de démonstrations, les exemples doivent donc être suffisamment représentatifs de la manière dont le geste sera effectué lors de l'utilisation. Ils doivent également rester suffisamment différents des exemples associés aux autres classes afin de limiter les confusions pendant la reconnaissance [81].

Reconnaissance en temps réel. Lors de l'utilisation, le modèle reçoit les vecteurs de mouvement les uns après les autres. À chaque nouvelle trame, il actualise la vraisemblance de chacune des classes gestuelles. Cette vraisemblance dépend à la fois de la proximité entre les nouvelles données et les distributions apprises, et de la cohérence de leur évolution avec les transitions temporelles du modèle. La classe reconnue correspond alors à celle dont la vraisemblance est la plus élevée. Le calcul est réalisé de manière causale, c'est-à-dire uniquement à partir

des données présentes et passées. Il n'est donc pas nécessaire d'attendre la fin du mouvement pour obtenir un résultat. Cette propriété permet au système de mettre à jour la reconnaissance pendant l'exécution du geste et de produire un retour sonore avec une faible latence, ce qui est essentiel pour maintenir une relation perceptible entre le mouvement de l'utilisateur et le son diffusé.

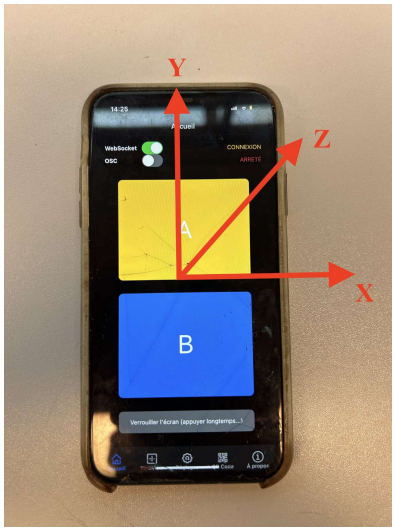
Le résultat doit néanmoins être interprété comme une comparaison entre les classes apprises, et non comme une certitude absolue. Le système détermine le geste le plus probable parmi les classes disponibles. En l'absence de seuil de rejet, un mouvement éloigné de tous les exemples peut malgré tout être associé à l'une d'elles. La qualité de la reconnaissance dépend donc de la pertinence des caractéristiques utilisées, de la diversité des exemples et du degré de différenciation entre les gestes. Dans notre cas, le fonctionnement général peut ainsi être résumé en quatre étapes : l'enregistrement d'exemples gestuels étiquetés, l'apprentissage de leur structure statistique et temporelle, l'estimation en temps réel de la vraisemblance de chaque classe, puis la sélection du son associé au geste considéré comme le plus probable.

3.3 Méthodes d'évaluation du capteur de mouvement

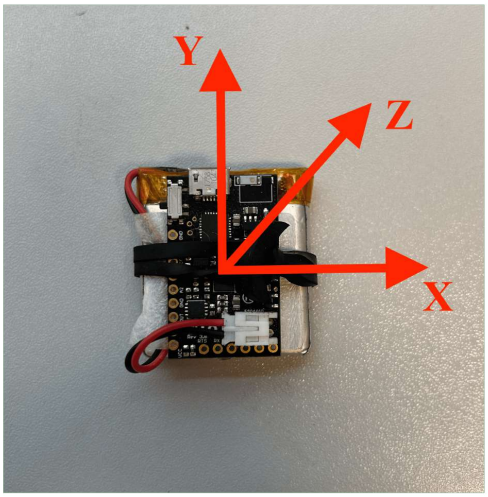
Notre processus d'évaluation a été conçu afin de qualifier de manière objective deux aspects complémentaires du système développé. Le premier concerne la capacité du dispositif à acquérir des données de mouvement de manière suffisamment stable pour une utilisation interactive en temps réel. Le second concerne la cohérence des mesures produites par le nouveau dispositif par rapport à d'autres systèmes de captation utilisés dans CoMo et servant de points de comparaison. L'objectif n'est donc pas uniquement de vérifier que le prototype fonctionne, mais de caractériser quantitativement la qualité des données produites, leur stabilité temporelle et leur proximité avec des dispositifs déjà utilisés dans le contexte du projet.

Le processus d'évaluation repose sur un banc de test composé de trois sources de mouvement fixées ensemble (cf. Fig. 12 et 13), orientées dans le même référentiel axial : le prototype utilisant son capteur dédié, un smartphone utilisé avec l'application *CoMote* [58], et un capteur *R-IoT* [59] (version 2). Ces trois dispositifs sont enregistrés simultanément afin de comparer leurs mesures sur une même fenêtre temporelle et pour un même mouvement.

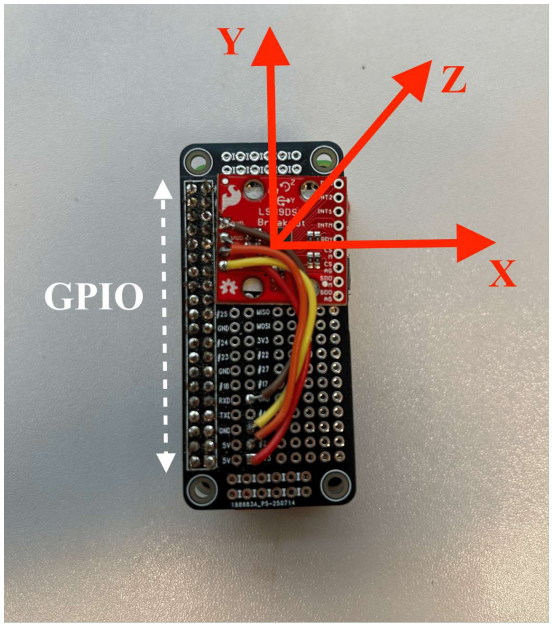
[58] https://apps.ismm.ircam.fr/comote
[59] https://github.com/ircam-ismm/riot-v3



(a) Smartphone sur lequel est lancée l'application CoMote

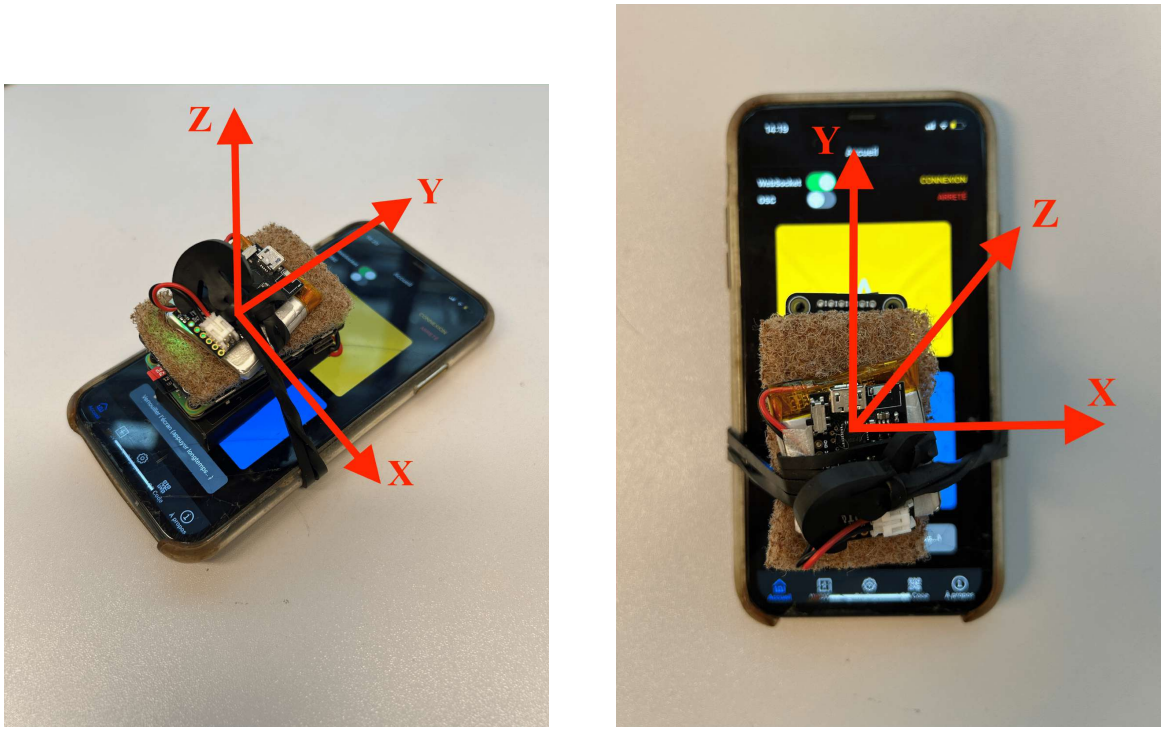


(b) Capteur R-IoT V.2



(c) Raspberry Pi Zero 2W disposant d'un capteur LSM9DS1 Breakout SparkFun et d'une batterie

Figure 12: Sources de mouvement du banc de test



(a) Vue de côté (b) Vue de haut

Figure 13: Banc de test composé d'une source CoMote, d'un R-IoT et d'un capteur LSM9DS1 branché sur un Raspberry Pi Zero 2W. Les trois sources de mouvement sont attachées entre elles, orientées dans le même référentiel axial, et connectées au même réseau.

Stabilité temporelle. Une première évaluation porte sur la stabilité temporelle des acquisitions. Pour chaque source, les périodes d'échantillonnage successives sont calculées à partir de la différence Δt_i entre deux timestamps consécutifs. À partir de ces périodes, la période moyenne d'acquisition est estimée par :

$$\overline{\Delta t} = \frac{1}{N-1} \sum_{i=2}^{N} \Delta t_i$$

Cette mesure permet de vérifier si la période réellement observée correspond à la période cible configurée dans le système. Elle est complétée par les périodes minimale et maximale. Ces indicateurs permettent d'identifier la tendance moyenne du système, mais aussi la présence d'événements ponctuels anormaux, comme des retards, des interruptions ou des paquets reçus de manière irrégulière.

La stabilité temporelle est également étudiée à travers le *jitter*. Dans ce contexte, le jitter correspond à l'écart entre la période réelle mesurée et la période nominale attendue. Pour une période de référence T_{ref}, le jitter (ms) est défini par :

$$j_i = \Delta t_i - T_{\text{ref}}$$

L'analyse du jitter permet d'évaluer la régularité du flux de données, ce qui est essentiel pour une application interactive. En effet, même si la fréquence moyenne est proche de la

fréquence cible, de fortes variations instantanées peuvent dégrader la stabilité du contrôle gestuel et provoquer des comportements irréguliers dans le système sonore. Les indicateurs retenus sont le jitter absolu moyen, le jitter minimal, le jitter maximal et la distribution des écarts autour de la période nominale.

Comparaison relative des données inertielles. Une seconde étape de l'évaluation consiste à comparer les valeurs mesurées par les différents capteurs sur une même fenêtre temporelle. Les variables comparées comprennent les trois axes de l'accéléromètre et les trois axes du gyroscope. La comparaison quantitative repose d'abord sur des métriques d'erreur (écart) axe par axe. Pour une grandeur donnée, par exemple la vitesse angulaire selon l'axe X, l'erreur instantanée entre une source a et une source de comparaison b est définie par :

$$e_{\text{gyroX},i} = \text{gyroX}_{a,i} - \text{gyroX}_{b,i}$$

où $\text{gyroX}_{\text{a},i}$ est donc la valeur mesurée par l'axe X du gyroscope de la source a à l'instant i, et $\text{gyroX}_{\text{b},i}$ est la valeur mesurée par la source de comparaison b au même instant, pour le même axe. Plusieurs indicateurs sont ensuite calculés : l'erreur moyenne, l'erreur moyenne absolue (MAE), l'erreur absolue maximale et l'écart quadratique moyen (RMSE). La comparaison est également effectuée par corrélation, puis complétée par le coefficient de Pearson. Celui-ci mesure l'intensité et le sens de la relation linéaire entre deux séries de valeurs. Il est défini comme le rapport entre la covariance des deux séries et le produit de leurs écarts-types :

$$r = \frac{\sum_{i=1}^{n}(x_i - \overline{x})(y_i - \overline{y})}{\sqrt{\sum_{i=1}^{n}(x_i - \overline{x})^2}\sqrt{\sum_{i=1}^{n}(y_i - \overline{y})^2}}$$

Sa valeur est comprise entre -1 et 1 inclus. Une valeur proche de 1 traduit une forte corrélation linéaire positive, tandis qu'une valeur proche de -1 indique une forte corrélation négative. Une valeur proche de 0 signale l'absence de relation linéaire marquée. Ce coefficient mesure toutefois la similarité des variations et non l'égalité des valeurs. Une forte corrélation peut ainsi être observée malgré la présence d'un biais systématique ou d'une différence d'échelle. Il doit donc être interprété en complément des autres indicateurs d'erreur utilisés.

4. Résultats et discussion

4.1 Système interactif embarqué et caractérisation

4.1.1 Description du dispositif embarqué

Capteur inertiel. Afin de proposer une alternative aux smartphones, le dispositif développé au cours de ce stage intègre un module SparkFun LSM9DS1 Breakout [60], fondé sur le circuit LSM9DS1 de STMicroelectronics. Ce capteur inertiel à neuf degrés de liberté (cf. Fig. 14) réunit un accéléromètre, un gyroscope et un magnétomètre, qui mesurent respectivement l'accélération, la vitesse angulaire et le champ magnétique selon les trois axes de l'espace. Il comporte en réalité deux sous-systèmes indépendants : l'un regroupe l'accéléromètre et le gyroscope, tandis que l'autre est consacré au magnétomètre. Cette séparation se traduit par des registres de configuration et des adresses I^2C distincts.

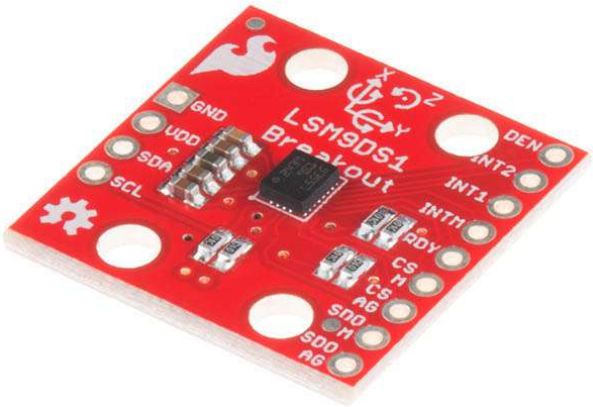


Figure 14: Capteur inertiel SparkFun LSM9DS1 Breakout

Le module SparkFun a été retenu pour son format compact, sa compatibilité avec les protocoles I^2C et SPI et sa facilité d'intégration sur une carte de prototypage. Ses plages de mesure sont configurables de ±2 à ±16 g pour l'accéléromètre, de ±245 à ±2000 °/s pour le gyroscope et de ±4 à ±16 gauss pour le magnétomètre. Les fréquences internes peuvent atteindre 952 Hz pour l'accéléromètre et le gyroscope et 80 Hz pour le magnétomètre. Dans ce travail, seules les mesures de l'accéléromètre et du gyroscope sont utilisées pour la caractérisation et l'interaction gestuelle ; le magnétomètre demeure disponible pour de futurs usages.

Dispositif embarqué. Le prototype rassemble les éléments nécessaires à la captation du mouvement, à son traitement et à la diffusion sonore (cf. Fig. 15), selon les couches présentées en section 3.2.1. Son architecture matérielle est organisée autour d'un Raspberry Pi Zero 2 W [61], auquel le LSM9DS1 est relié en I^2C via les GPIO (cf. Fig. 18) au moyen d'une carte de prototypage et d'un connecteur (cf. Fig. 17). Une carte Raspiaudio MIC+ [62] assure la diffusion audio, tandis qu'une batterie PiSugar S [63] alimente l'ensemble. Le dispositif forme ainsi un

[60] https://www.sparkfun.com/sparkfun-9dof-imu-breakout-lsm9ds1.html
[61] https://www.raspberrypi.com/products/raspberry-pi-zero-2-w/
[62] https://raspiaudio.com/product/mic/
[63] https://www.pisugar.com/products/pisugar-s-raspberry-pi-zero-battery

système autonome et sans fil (cf. Fig. 16), capable de produire localement une réponse sonore en fonction des mouvements de l'utilisateur.

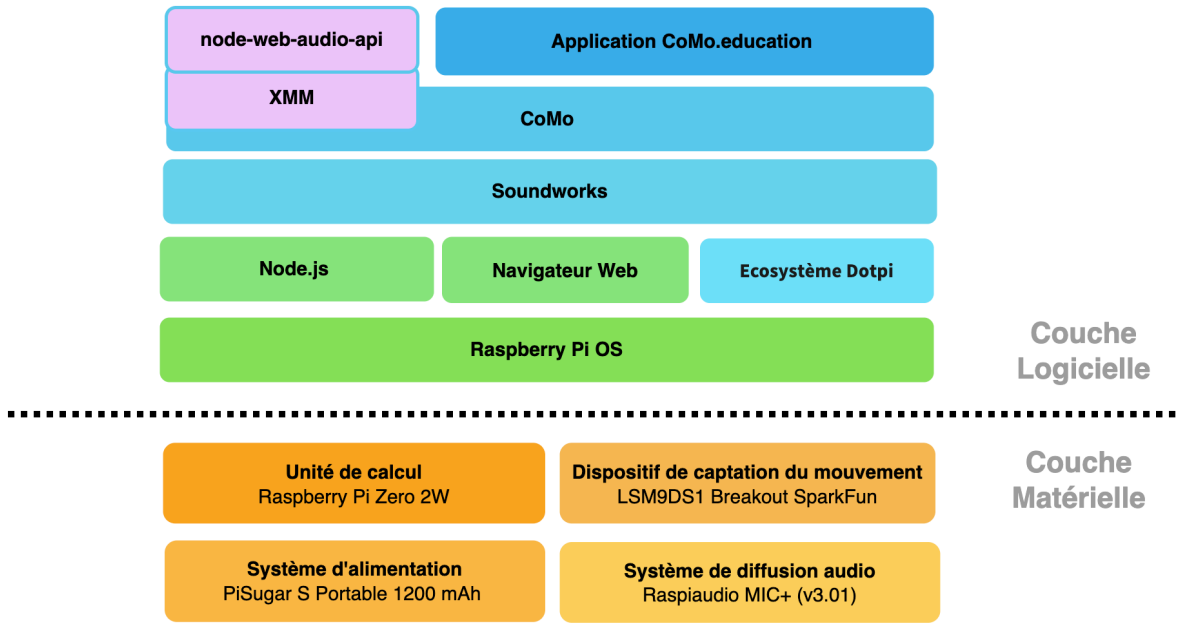


Figure 15: Couches logicielles et matérielles de notre système sonore interactif embarqué

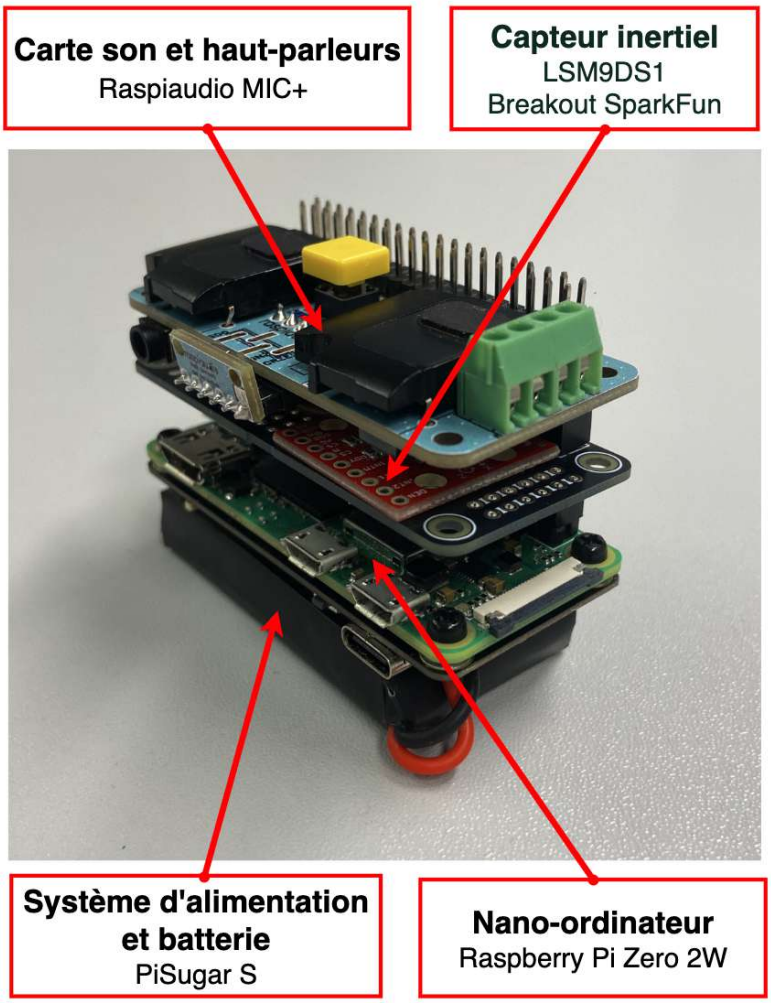


Figure 16: Dispositif interactif embarqué réalisé durant le stage et disposition des éléments matériels

4.1.2 Acquisition des données inertielles

L'acquisition consiste à configurer le capteur, à lire périodiquement ses mesures, à les convertir en unités physiques, puis à les publier dans le format unifié de CoMo.

Communication entre le Raspberry Pi Zero 2W et le capteur. Le LSM9DS1 communique avec le Raspberry Pi par le bus I^2C, directement pris en charge par les deux composants. Le câblage (cf. Fig. 17 et 18) repose alors sur quatre connexions : l'alimentation VDD est reliée à la broche 3,3 V (PIN 1), la masse à une broche GND (PIN 9), la ligne SDA (Serial Data Line) au GPIO 2 (PIN 3) et la ligne SCL (Serial Clock Line) au GPIO 3 (PIN 5). Cette liaison limite le nombre de connexions nécessaires tout en permettant de configurer et d'interroger les deux sous-systèmes du capteur.

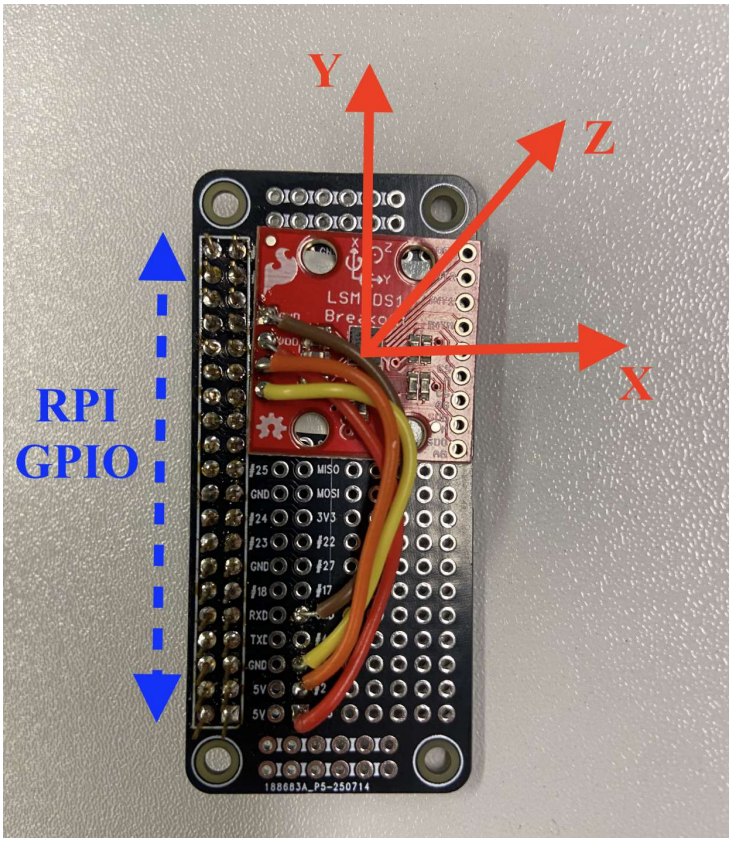


Figure 17: Capteur LSM9DS1 Breakout SparkFun fixé et soudé sur une carte de prototypage pour Raspberry Pi Zero, relié à un support GPIO (liaison faite directement sur la carte utilisée). Ici, le fil rouge connecte l'alimentation 3,3V, le fil marron connecte la masse, le fil orange connecte la SDA, et le fil jaune connecte la SCL

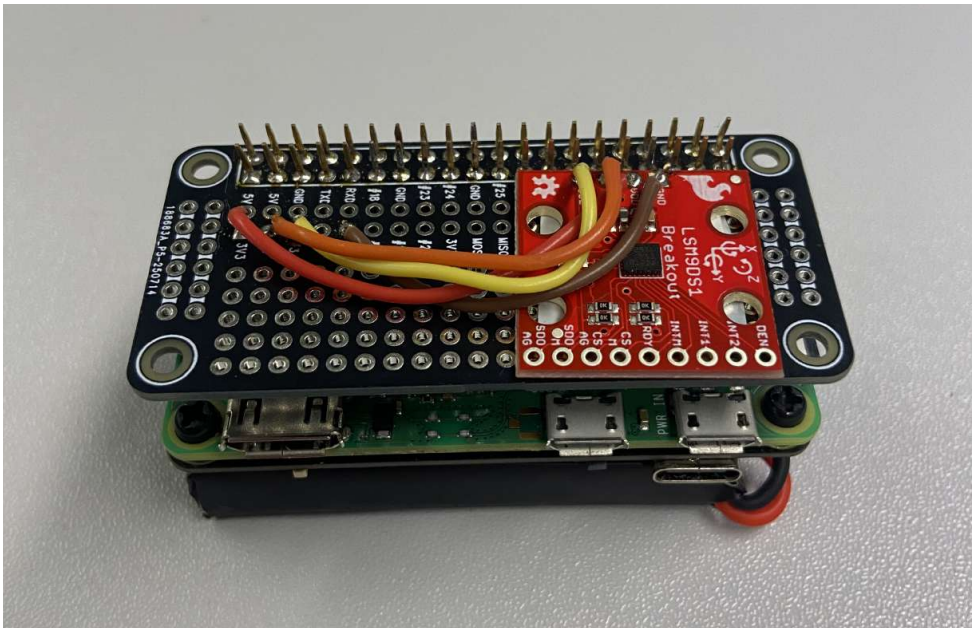


Figure 18: Capteur LSM9DS1 Breakout SparkFun connecté au Raspberry Pi Zero via un connecteur GPIO

Acquisition des données. L'acquisition a été développée en JavaScript au sein de CoMo. En l'absence de bibliothèque Node.js dédiée au LSM9DS1, la bibliothèque *i2c* [64] est utilisée pour lire et écrire directement dans ses registres. La nouvelle classe *Lsm9ds1Source*, dérivée de la classe abstraite *AbstractSource*, assure l'initialisation du capteur, son interrogation périodique et la mise à disposition des données dans le framework.

Lors de l'initialisation, deux connexions I^2C sont ouvertes : l'adresse 0x6B donne accès à l'accéléromètre et au gyroscope, tandis que l'adresse 0x1E correspond au magnétomètre. Les plages retenues sont de ±8 g pour l'accéléromètre ($\approx \pm 78$ m/s^2), de ±2000 °/s pour le gyroscope ($\approx \pm 34$ rad/s) et de ±12 gauss pour le magnétomètre (1200 μT). Elles ont été définies à partir d'essais comportant des mouvements rapides et de grande amplitude, de manière à conserver une marge suffisante pour éviter la saturation. Les fréquences internes sont fixées à 238 Hz pour l'accéléromètre et le gyroscope et à 80 Hz pour le magnétomètre. Elles doivent être distinguées de la fréquence d'interrogation logicielle, fixée par défaut à 100 Hz, soit une période demandée de 10 ms, jugée suffisante pour l'interaction son-mouvement.

À chaque acquisition, les valeurs brutes codées sur 16 bits signés sont lues puis converties dans les unités attendues. Les axes X et Y sont permutés afin d'adopter le même repère que les autres sources de CoMo. Les mesures sont ensuite regroupées dans une frame contenant l'identifiant de la source, sa fréquence, un horodatage précis (*timestamp*) et les données de l'accéléromètre, du gyroscope et du magnétomètre (cf. Annexe 2). La bibliothèque *@ircam/sc-motion* complète cette frame par une estimation de la gravité avant sa publication dans CoMo, où elle devient accessible aux modules de visualisation, d'enregistrement, de reconnaissance gestuelle et de contrôle sonore.

Le timestamp (obtenu à l'aide d'une méthode *process.hrtime()* [65]) est calculé une seule fois au cours de chaque cycle d'acquisition. Il constitue donc la référence temporelle de la frame reconstruite par le programme, et non l'instant physique exact auquel chaque axe a été mesuré. Cette convention permet néanmoins d'analyser la stabilité de l'acquisition et de comparer la nouvelle source aux dispositifs existants.

4.1.3 Évaluation et optimisation

L'évaluation est réalisée au moyen d'un client Node.js exécuté sur le Raspberry Pi. **Le code source utilisé pour l'acquisition et l'enregistrement simultané des données est disponible dans le dépôt GitHub présenté en Annexe 1.** Le client node instancie les trois sources et enregistre leurs trames dans des fichiers séparés. Chaque trame contient notamment un temps relatif commun, un indice d'échantillon et la frame de mouvement correspondante (cf. Annexe 2). Les acquisitions durent environ quatre minutes et sont analysées sur une fenêtre fixe de trois minutes, obtenue en excluant les trente premières et les trente dernières secondes. L'objectif n'est pas d'établir une équivalence métrologique stricte entre les dispositifs, mais de vérifier que le LSM9DS1 produit des données temporellement exploitables et globalement cohérentes avec les sources déjà utilisées dans CoMo.

[64] https://github.com/kelly/node-i2c
[65] https://nodejs.org/api/process.html#processhrtimetime

a) Stabilité temporelle

La stabilité temporelle est évaluée pour des intervalles de référence de 10, 20 et 40 ms, correspondant respectivement à des fréquences de 100, 50 et 25 Hz. Le jitter désigne ici la différence entre la période observée entre deux trames et la période demandée : une valeur positive correspond à un retard, tandis qu'une valeur négative indique deux acquisitions plus rapprochées que prévu. Le jitter absolu moyen décrit l'écart habituel à la consigne, alors que ses valeurs extrêmes mettent en évidence les irrégularités ponctuelles.

Avant optimisation, les périodes moyennes restent proches des consignes (cf. Tableau 2), mais le LSM9DS1 présente une instabilité plus marquée à 10 ms : sa période moyenne atteint 10,79 ms, soit 92,61 Hz, et son jitter absolu moyen est de 2,25 ms. Une période maximale de 276,13 ms (cf. Annexe 3) produit en outre un jitter ponctuel de 266,13 ms. CoMote et le R-IoT présentent également des retards isolés, respectivement de 161 et 67,87 ms. Contrairement au LSM9DS1, dont les mesures sont acquises localement via le bus I^2C du Raspberry Pi, les données de CoMote et du R-IoT transitent par le réseau Wi-Fi, respectivement au moyen de WebSockets et de messages OSC. Leur temporalité observée intègre donc également des variations, liées notamment à la transmission et à l'acheminement des données sur le réseau. Les distributions (cf. Fig. 19) demeurent donc majoritairement concentrées autour de zéro, mais comportent des valeurs extrêmes susceptibles de perturber localement la régularité de l'acquisition.

Note : Ces résultats sont obtenus en considérant 3 minutes de données.

Intervalle (ms)	**Source**	**Période moyenne (ms)**	**Jitter absolu moyen (ms)**	**Jitter max. (ms)**	**Jitter min. (ms)**
10	**LSM9DS1**	**10,79**	**2,25**	**266,13**	**−9,31**
	CoMote	10,20	0,51	161,00	−9,00
	R-IoT	10,00	2,05	67,87	−9,16
20	LSM9DS1	20,34	0,98	87,25	−18,93
	CoMote	20,23	0,80	55,00	−19,00
	R-IoT	20,00	2,05	117,83	−18,85
40	LSM9DS1	40,27	0,76	46,57	−35,38
	CoMote	40,20	1,01	28,00	−28,00
	R-IoT	40,05	1,83	46,14	−38,19

Tableau 2: Comparaison des résultats du jitter, en fonction de la source et de l'intervalle d'échantillonnage

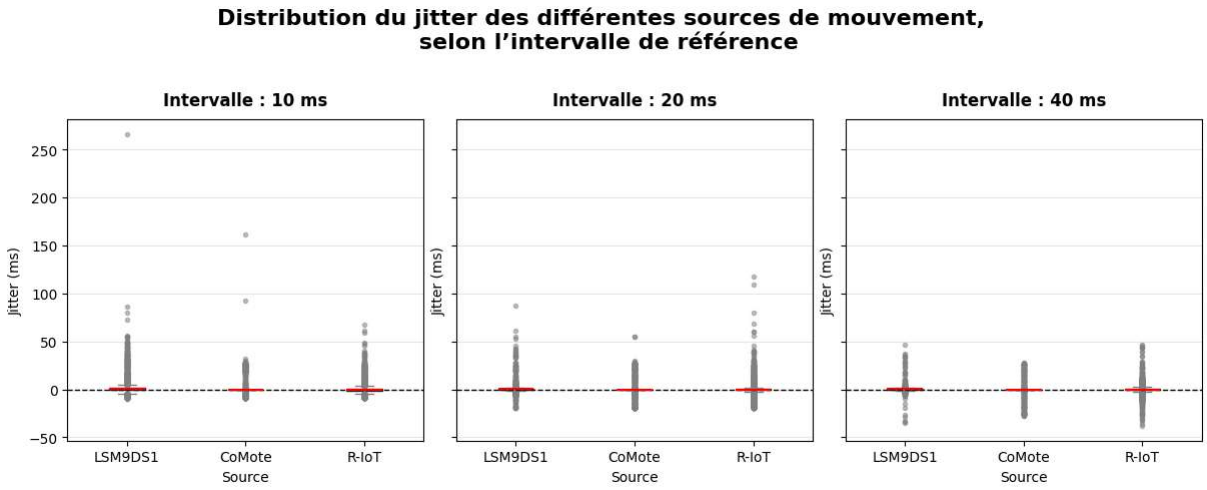


Figure 19: Distribution du jitter des trois sources de mouvement avant l'optimisation temporelle du LSM9DS1, pour des intervalles de référence de 10, 20 et 40 ms.

Optimisation temporelle du LSM9DS1. Dans l'implémentation initiale, la lecture du capteur, le traitement des données et leur publication étaient exécutés dans le *thread* (fil d'exécution) principal (*main thread*) du process Node.js. Les acquisitions périodiques (déclenchées avec la fonction *setInterval()*) pouvaient donc être retardées et irrégulières lorsque cette boucle était occupée par une autre opération (e.g. *garbage collection*). L'optimisation a consisté à déplacer la communication I^2C, la conversion des mesures et la construction des frames dans un *Worker Thread* [66], c'est-à-dire un thread de travail distinct. Le thread principal reçoit désormais les trames produites et les publie dans CoMo, ce qui limite l'influence des autres traitements sur la cadence de lecture.

Le mécanisme d'acquisition périodique fondé sur la fonction native *setInterval* a également été remplacé par une boucle fondée sur les instants d'acquisition théoriques, à partir d'une référence temporelle commune et de l'intervalle demandé. Comme le montre l'algorithme ci-dessous (cf. Pseudo-code 1), l'instant théorique de la prochaine acquisition est calculé en ajoutant la période demandée T à l'échéance précédente. Le thread de travail attend que cette échéance soit atteinte, puis réalise entièrement la lecture du capteur avant de transmettre la trame au thread principal. Chaque lecture est terminée avant le déclenchement de la suivante, ce qui limite leur chevauchement. Comme chaque échéance est déterminée à partir de la référence temporelle précédente, et non à partir de la fin de la dernière lecture, un retard ponctuel ne décale pas systématiquement l'ensemble des acquisitions suivantes (cf. Fig. 20). Si l'échéance est déjà dépassée au terme d'une lecture, l'attente est simplement omise et l'acquisition suivante est exécutée immédiatement.

[66] https://nodejs.org/api/worker_threads.html

Pseudo-code 1 Mécanisme d'acquisition périodique des données du LSM9DS1 mis en œuvre dans le thread de travail distinct

```
1: t_cible ← t_actuel
2: Tant que (l'acquisition est active) faire
3:     t_cible ← t_cible + T
4:     Tant que (l'acquisition est active et t_actuel < t_cible) faire
5:         Attendre
6:     Fin Tant que
7:     trame ← LireCapteur()
8:     Si la trame est valide alors
9:         Transmettre la trame au thread principal
10:    Fin Si
11: Fin Tant que
```

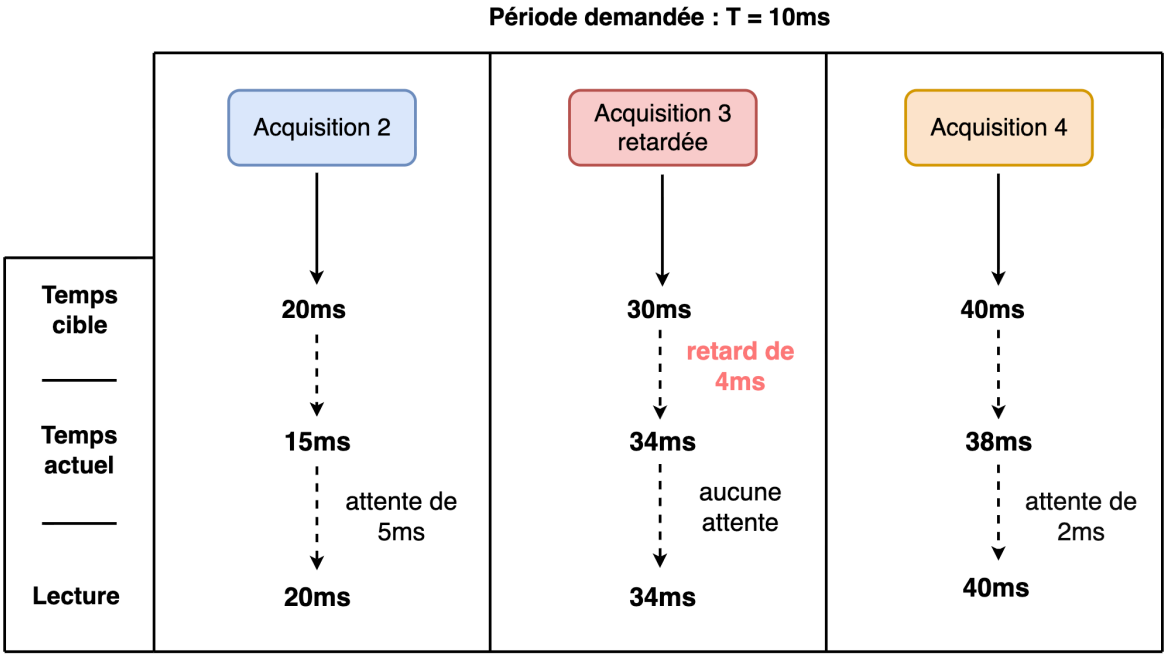


Figure 20: Principe de compensation d'un retard ponctuel par une planification fondée sur des échéances théoriques. Contrairement à une planification calculée à partir de la dernière acquisition réelle, les échéances restent définies par rapport à une référence temporelle commune. Un retard affecte ainsi l'acquisition concernée sans être systématiquement reporté sur les acquisitions suivantes.

Cette organisation améliore nettement la régularité du LSM9DS1 (cf. Annexe 4). Pour une période demandée de 10 ms, la période moyenne passe de 10,79 à 10,00 ms et le jitter absolu moyen de 2,25 à 0,97 ms, soit une amélioration d'environ 57 % (cf. Tableau 3). Le jitter maximal est également réduit de 266,13 à 35,84 ms (cf. Fig. 21). Selon l'intervalle étudié, la diminution du jitter absolu moyen atteint 46 à 62 %. Des variations ponctuelles persistent en raison de l'ordonnancement du système d'exploitation et de la durée des communications I^2C, mais les fréquences moyennes correspondent désormais aux consignes de 100, 50 et 25 Hz.

Note : Comme précédemment, ces résultats sont obtenus en considérant trois minutes de données.

Intervalle (ms)	Source	Période moyenne (ms)	Jitter absolu moyen (ms)	Jitter max. (ms)	Jitter min. (ms)
10	**LSM9DS1**	**10,00**	**0,97**	**35,84**	**−6,53**
	CoMote	10,20	0,55	33,00	−9,00
	R-IoT	10,00	2,63	123,75	−9,24
20	LSM9DS1	20,00	0,53	30,03	−15,66
	CoMote	20,22	0,80	32,00	−19,00
	R-IoT	20,00	1,87	74,14	−19,08
40	LSM9DS1	39,99	0,29	15,65	−14,91
	CoMote	40,20	1,15	32,00	−32,00
	R-IoT	40,00	0,98	47,47	−38,86

Tableau 3: Comparaison des résultats du jitter après l'optimisation temporelle du LSM9DS1, en fonction de la source et de l'intervalle d'échantillonnage

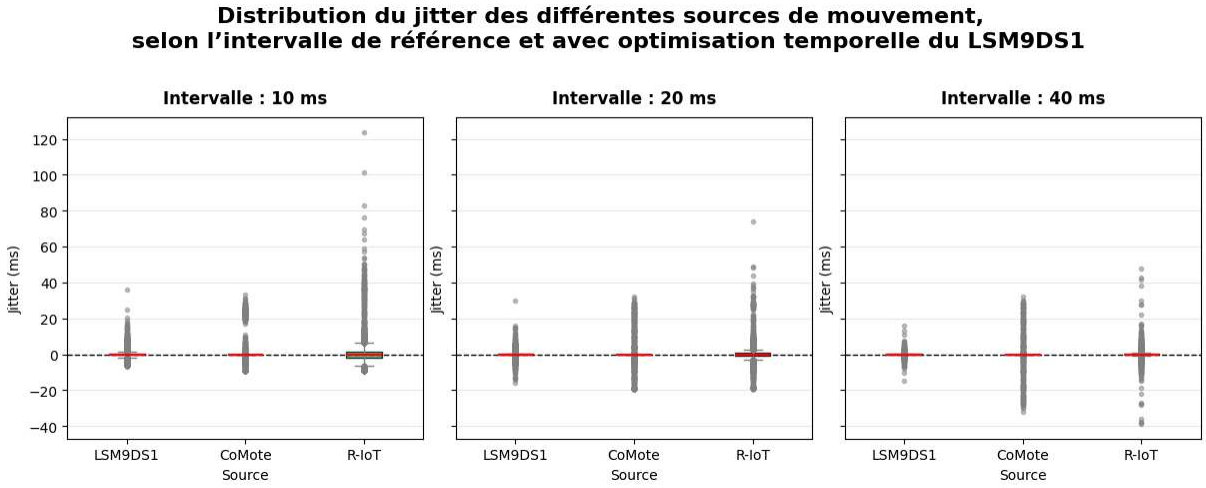


Figure 21: Distribution du jitter des trois sources de mouvement après l'optimisation temporelle du LSM9DS1, pour des intervalles de référence de 10, 20 et 40 ms.

Les représentations des instants d'acquisition sur une fenêtre de 200 ms confirment localement cette évolution (cf. Annexe 5) : après optimisation, les mesures se rapprochent davantage de la grille théorique et un retard ne se propage plus systématiquement aux acquisitions suivantes. Dans les conditions testées, la stabilité temporelle du LSM9DS1 devient ainsi comparable à celle de CoMote et du R-IoT, voire supérieure pour certains intervalles, sans que le jitter soit totalement supprimé.

b) Comparaison des données inertielles

La comparaison est menée au repos puis au cours de trois séquences dynamiques : une séquence de rotations lentes et rapides destinée au gyroscope, une séquence associant changements d'orientation, translations et secousses pour l'accéléromètre, et une séquence de mouvements libres plus proche d'un usage interactif. Chaque acquisition dure environ quatre minutes et l'analyse porte, comme précédemment, sur une fenêtre de trois minutes commençant trente secondes après le début de l'enregistrement. Les écarts sont calculés axe par axe pour les trois

paires de sources.

Le système n'acquérant pas exactement aux mêmes instants les données des trois sources de mouvement, leurs signaux sont interpolés sur une grille temporelle théorique commune (cf. Annexe 6), afin de les comparer échantillon par échantillon. La fréquence de cette grille correspond à la plus faible fréquence moyenne des trois sources, afin de ne pas créer artificiellement une résolution supérieure à celle du dispositif le plus lent. Les comparaisons reposent sur le coefficient de corrélation de Pearson, l'erreur moyenne signée, la MAE, la RMSE et l'erreur absolue maximale. Le coefficient r caractérise la similarité de l'évolution linéaire des signaux ; l'erreur moyenne renseigne sur leur biais ; la MAE décrit l'écart usuel ; enfin, une RMSE nettement supérieure à la MAE révèle la présence d'écarts ponctuels importants. Les diagrammes de corrélation permettent également de comparer la droite de régression à l'accord parfait $y = x$.

1. Mesures réalisées au repos

Au repos, les trois gyroscopes fournissent des mesures très proches : les MAE sont comprises entre 0 et 0,06 rad/s et les erreurs absolues maximales ne dépassent pas 0,07 rad/s (cf. Annexe 7). Les différences sont plus marquées pour l'accéléromètre, notamment sur l'axe y entre le R-IoT et CoMote, où l'erreur moyenne atteint -1,23 m/s^2 ; elles restent inférieures à 0,80 m/s^2 pour les autres comparaisons. La proximité entre la valeur absolue de l'erreur moyenne, la MAE et la RMSE suggère que ces écarts proviennent principalement de décalages relativement constants, potentiellement liés à l'orientation du banc et aux caractéristiques intrinsèques des capteurs, plutôt qu'à une forte variabilité aléatoire.

2. Mesures réalisées en mouvement

a) Séquence consacrée au gyroscope

Les coefficients de corrélation, compris entre 0,963 et 0,996, montrent que les trois sources reproduisent de façon très similaire les variations de vitesse angulaire (cf. Fig. 22). La meilleure correspondance et les erreurs usuelles les plus faibles sont globalement observées entre le LSM9DS1 et le R-IoT (cf. Tableau 4), tandis que les comparaisons impliquant CoMote sont légèrement plus dispersées. Les erreurs moyennes restent proches de zéro, mais des différences locales subsistent : sur l'axe Y, l'erreur absolue maximale atteint 19,88 rad/s entre le LSM9DS1 et CoMote. La RMSE supérieure à la MAE indique que ces écarts sont ponctuels et ne remettent pas en cause la cohérence de la dynamique mesurée.

Note : Ces résultats sont obtenus en considérant 3 minutes de données, pour un intervalle de 10 ms, soit environ 18 000 échantillons. L'erreur est calculée en soustrayant les valeurs mesurées par la deuxième source à celles mesurées par la première source.

Comparaison	**Capteur**	**Axe**	**Erreur moyenne**	**MAE**	**RMSE**	**Erreur absolue max.**	**Coeff. Pearson r**
LSM9DS1 – CoMote	Gyroscope (rad/s)	X	0,08	0,53	0,91	9,70	0,969
		Y	−0,09	0,47	0,92	19,88	0,969
		Z	0,04	0,29	0,51	7,15	0,993
LSM9DS1 – R-IoT	Gyroscope (rad/s)	X	0,04	0,42	0,63	7,41	0,996
		Y	−0,05	0,36	0,55	12,99	0,991
		Z	0,00	0,44	0,69	7,48	0,995
R-IoT – CoMote	Gyroscope (rad/s)	X	0,04	0,62	0,94	9,15	0,975
		Y	−0,03	0,63	1,04	18,02	0,963
		Z	0,03	0,54	0,82	8,96	0,989

Tableau 4: Erreurs mesurées entre les gyroscopes des différentes sources en mouvement

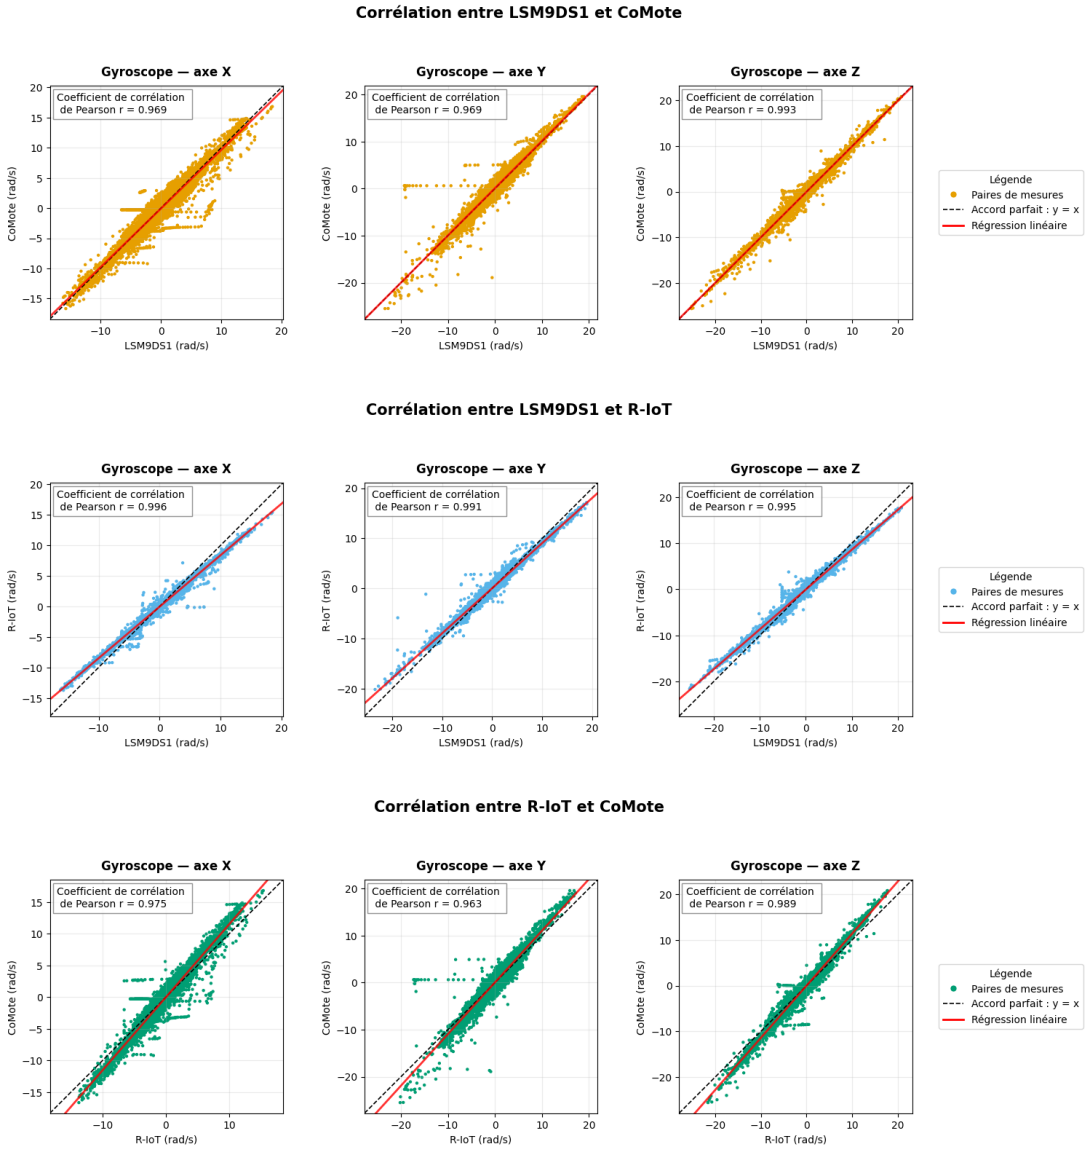


Figure 22: Corrélations entre les données gyroscopiques des trois sources de mouvement, lors de la séquence consacrée au gyroscope (pour un intervalle de 10 ms et sur une fenêtre temporelle de 3 minutes)

b) Séquence consacrée à l'accéléromètre

Les trois paires de sources restent fortement corrélées, avec des coefficients supérieurs à 0,9, mais leurs écarts sont plus importants que pour le gyroscope (cf. Fig. 23). Le LSM9DS1 et le R-IoT présentent de nouveau la meilleure concordance et les erreurs les plus faibles, tandis que les comparaisons impliquant CoMote sont plus dispersées, en particulier avec le R-IoT (cf. Tableau 5). Les trois accéléromètres reproduisent donc une dynamique similaire sans toujours mesurer la même amplitude. Ainsi, malgré un coefficient de 0,986, l'erreur absolue maximale atteint 38,48 m/s^2 entre le LSM9DS1 et le R-IoT sur l'axe Y. Une forte corrélation peut donc coexister avec des écarts instantanés importants.

Note : Ces résultats sont également obtenus en considérant 3 minutes de données, pour un intervalle de 10 ms, soit environ 18 000 échantillons. L'erreur est calculée en soustrayant les valeurs mesurées par la deuxième source à celles mesurées par la première source.

Comparaison	**Capteur**	**Axe**	**Erreur moyenne**	**MAE**	**RMSE**	**Erreur absolue max.**	**Coeff. Pearson r**
LSM9DS1 – CoMote	Accéléromètre (m/s^2)	X	−0,10	1,51	2,19	27,30	0,962
		Y	−0,24	1,58	2,36	18,97	0,950
		Z	−0,32	1,24	2,07	17,63	0,967
LSM9DS1 – R-IoT	Accéléromètre (m/s^2)	X	−0,49	0,76	1,14	19,00	0,992
		Y	0,09	0,81	1,29	38,48	0,986
		Z	0,62	1,00	1,54	18,09	0,985
R-IoT – CoMote	Accéléromètre (m/s^2)	X	0,39	1,74	2,67	34,09	0,943
		Y	−0,34	2,10	3,07	25,88	0,919
		Z	−0,95	1,74	2,72	21,13	0,945

Tableau 5: Erreurs mesurées entre les accéléromètres des différentes sources en mouvement

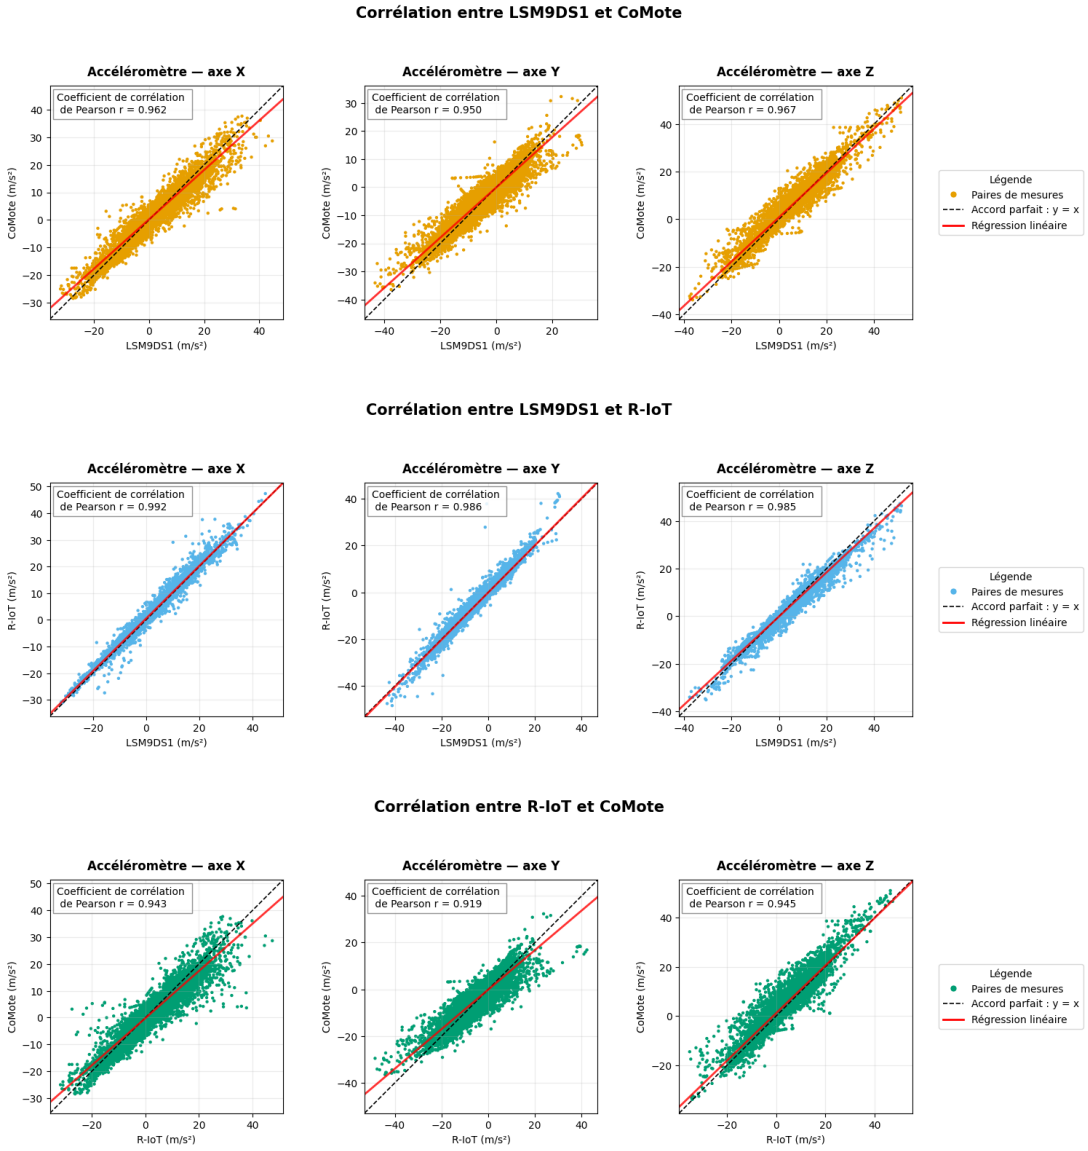


Figure 23: Corrélations entre les données accélérométriques des trois sources de mouvement, lors de la séquence consacrée à l'accéléromètre (pour un intervalle de 10 ms et sur une fenêtre temporelle de 3 minutes)

c) Séquence de mouvements libres

La séquence de mouvements libres confirme les tendances précédentes dans une gestuelle plus diversifiée. Pour l'accéléromètre, le LSM9DS1 et le R-IoT restent les sources les plus cohérentes, tandis que les comparaisons impliquant CoMote sont légèrement moins corrélées ; la paire R-IoT–CoMote présente également les erreurs les plus élevées (cf. Annexes 8 et 9). Les résultats gyroscopiques sont plus homogènes : la paire LSM9DS1–R-IoT obtient les corrélations les plus fortes, et les écarts les plus importants concernent de nouveau le R-IoT et CoMote sans remettre en cause la similarité globale des signaux.

Dans l'ensemble des séquences en mouvement, les coefficients sont compris entre 0,914 et 0,998. Les trois sources décrivent donc de manière cohérente la dynamique générale des gestes. La correspondance est globalement la plus forte entre le LSM9DS1 et le R-IoT, particulière-

ment pour l'accélération, et les mesures gyroscopiques apparaissent plus homogènes que les mesures accélérométriques. Des différences d'amplitude parfois importantes demeurent en raison des caractéristiques propres aux dispositifs, mais elles ne constituent pas nécessairement une incohérence : l'objectif est ici de vérifier la comparabilité de la dynamique, et non l'égalité instantanée des mesures. À ce titre, le LSM9DS1 apparaît compatible avec les sources déjà intégrées à CoMo.

4.2 Nouvelle application web et système final

4.2.1 Cahier des charges

CoMo.education accompagne des activités collectives de narration gestuelle et sonore en maternelle. L'application doit permettre à l'enseignant de préparer puis de conduire une « histoire » interactive dans laquelle les gestes des enfants sont reconnus et associés en temps réel à des sons. L'enfant perçoit ainsi directement la conséquence sonore de son mouvement et peut adapter son action.

Le système doit s'intégrer à différents contextes (e.g. scolaire, ateliers), favoriser l'expression, l'écoute, l'engagement corporel et la coopération, tout en restant adaptable aux objectifs pédagogiques. Les enseignants et les médiateurs doivent pouvoir le configurer sans intervenir dans le code ni maîtriser le fonctionnement interne de la reconnaissance. L'interface doit donc employer un vocabulaire compréhensible et guider clairement les étapes de création, de modification et d'exécution. L'activité étant collective, plusieurs enfants doivent pouvoir participer simultanément avec des dispositifs personnels, sans fil et capables de diffuser localement leur réponse sonore.

L'interface web doit permettre de créer, modifier et lancer une histoire. Une histoire regroupe dans une même session sa configuration, les gestes appris, leurs exemples et les correspondances geste-son. Pour chaque geste, l'utilisateur renseigne un nom, choisit un son et enregistre une démonstration du mouvement destinée à l'apprentissage. Un décompte prépare l'utilisateur à l'enregistrement ; une phase de test permet ensuite de valider la reconnaissance ou de recommencer. L'utilisateur doit également pouvoir renommer une histoire, ajouter ou supprimer un geste et définir une catégorie associée au silence.

Dans l'ancienne application, les sons devaient être placés à l'avance dans la banque du serveur. La nouvelle version doit permettre l'importation directe de fichiers personnels, conformément à une demande des médiatrices. Cette fonction doit faciliter l'adaptation des histoires et rendre possible un travail pédagogique portant aussi sur l'enregistrement ou la conception des sons du récit.

Le redéveloppement doit ainsi conserver les principes de l'application existante ; gestion des histoires, apprentissage des gestes, association geste-son et exécution distribuée ; tout en intégrant la nouvelle source. Il doit dissocier l'interface de contrôle exécutée sur l'ordinateur du dispositif chargé de la captation, de la reconnaissance et de la diffusion sonore, et rester compatible avec les sessions et les états partagés de CoMo.

4.2.2 Description de l'application

Architecture. L'application repose sur quatre entités : un serveur central, une interface web destinée à l'utilisateur, un client Node.js exécuté sur le dispositif embarqué et un script temps réel reliant les données de mouvement, le modèle XMM et la synthèse sonore (cf. Fig. 24).

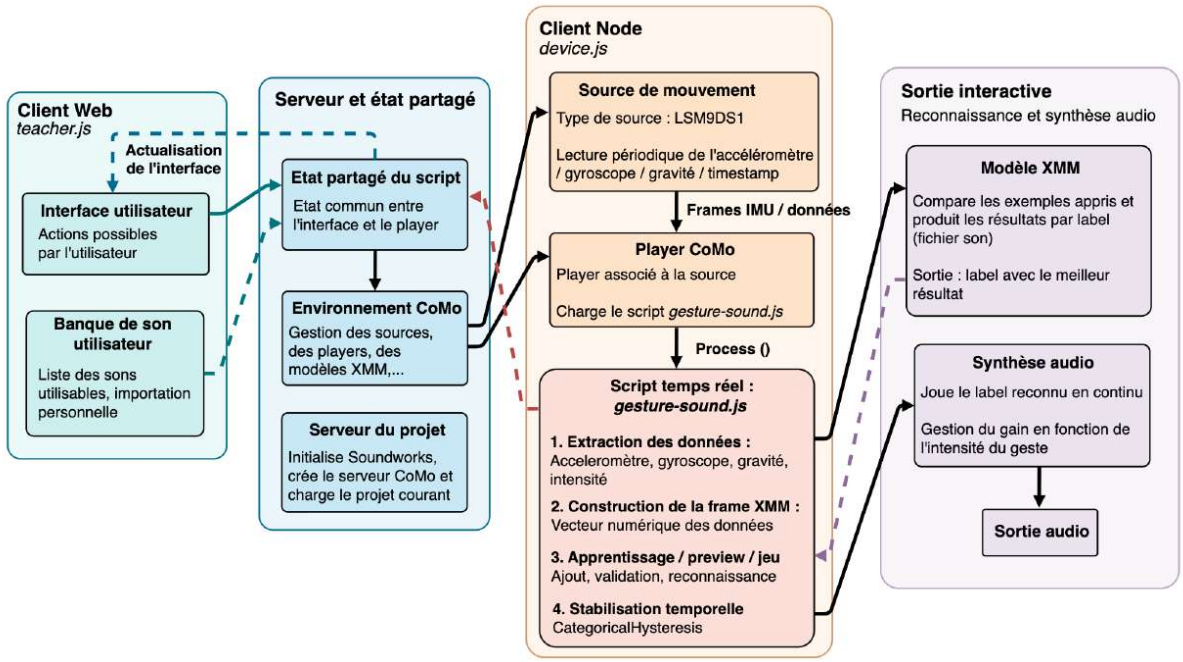


Figure 24: Architecture fonctionnelle de la nouvelle application web CoMo.education

Le serveur initialise Soundworks, CoMo et le projet courant. Il gère les sources, les players, les scripts, les états partagés et les ressources, et fournit l'infrastructure de communication entre les clients sans traiter lui-même les données gestuelles. Le client *device* crée une source de type « *lsm9ds1* », lui associe un player CoMo et charge le script *gesture-sound.js.* Celui-ci reçoit périodiquement les mesures d'accélération, de vitesse angulaire et de gravité, construit les descripteurs transmis à XMM et commande une classe de synthèse chargée de la banque sonore (*soundbank*), de la lecture des fichiers et des transitions entre ces derniers. Le client web *teacher* agit sur le système par l'intermédiaire de l'état partagé (*shared state*). Cette séparation permet de modifier indépendamment l'interface, la reconnaissance, la synthèse ou la source de mouvement. **Le code source de l'application CoMo.education développée dans le cadre de ce stage est disponible dans le dépôt GitHub présenté en Annexe 1**.

Intensité et stabilisation. Afin d'obtenir une qualité d'interaction similaire à celle de l'application précédente, deux traitements complètent la reconnaissance : une estimation de l'intensité du geste [67] et un mécanisme de stabilisation [68]. L'intensité du geste est estimée à partir de la variation de l'accélération dans une fenêtre glissante. Pour chaque axe, une régression linéaire fournit une pente, ensuite lissée par rétroaction ; la somme des carrés des trois composantes produit un indicateur global utilisé pour contrôler le gain sonore. Le volume dépend ainsi de l'énergie du mouvement plutôt que de la seule accélération instantanée.

[67] https://github.com/ircam-ismm/sc-motion/blob/main/src/Intensity.js
[68] https://github.com/ircam-ismm/sc-signal/blob/main/src/CategoricalHysteresis.js

La stabilisation limite les changements répétés entre catégories voisines. Un buffer circulaire conserve les derniers gestes détectés et détermine la catégorie courante par vote majoritaire. En cas d'égalité, le dernier état validé est conservé. Cette légère inertie réduit les commutations sonores intempestives dues au bruit ou aux fluctuations du mouvement et rend l'interaction plus lisible et cohérente pour l'utilisateur.

Fonctionnalités et interface utilisateur. Sur un écran d'ordinateur en plein écran, les fonctions principales sont réunies sur une page sans défilement (cf. Fig. 25) ; sur un écran plus petit, la mise en page s'adapte et autorise le défilement. L'utilisateur peut importer des sons par glisser-déposer, les écouter, les sélectionner ou les supprimer, nommer et enregistrer un geste, tester puis valider ou annuler l'exemple, et gérer la liste des démonstrations enregistrées.

En mode **Création**, l'utilisateur choisit un son, nomme le geste et lance l'enregistrement. Un décompte vocal de trois secondes lui permet de se préparer ; la capture réelle commence une seconde après la fin du décompte afin que le mouvement soit déjà amorcé. À chaque nouvelle trame, un vecteur de dix valeurs est construit à partir des trois axes de l'accéléromètre, des trois axes du gyroscope, des trois composantes de la gravité estimée et de l'intensité globale. L'enregistrement dure quatre secondes puis s'arrête automatiquement. L'exemple est ajouté temporairement au modèle pour être testé : il n'est conservé définitivement qu'après validation, et peut sinon être annulé puis réenregistré.

En mode **Jouer**, les trames sont analysées en continu par XMM. Le label obtenu est transmis au mécanisme de stabilisation, qui valide le geste majoritaire. Le script déclenche alors en boucle le son correspondant jusqu'à la reconnaissance stable d'une autre catégorie.

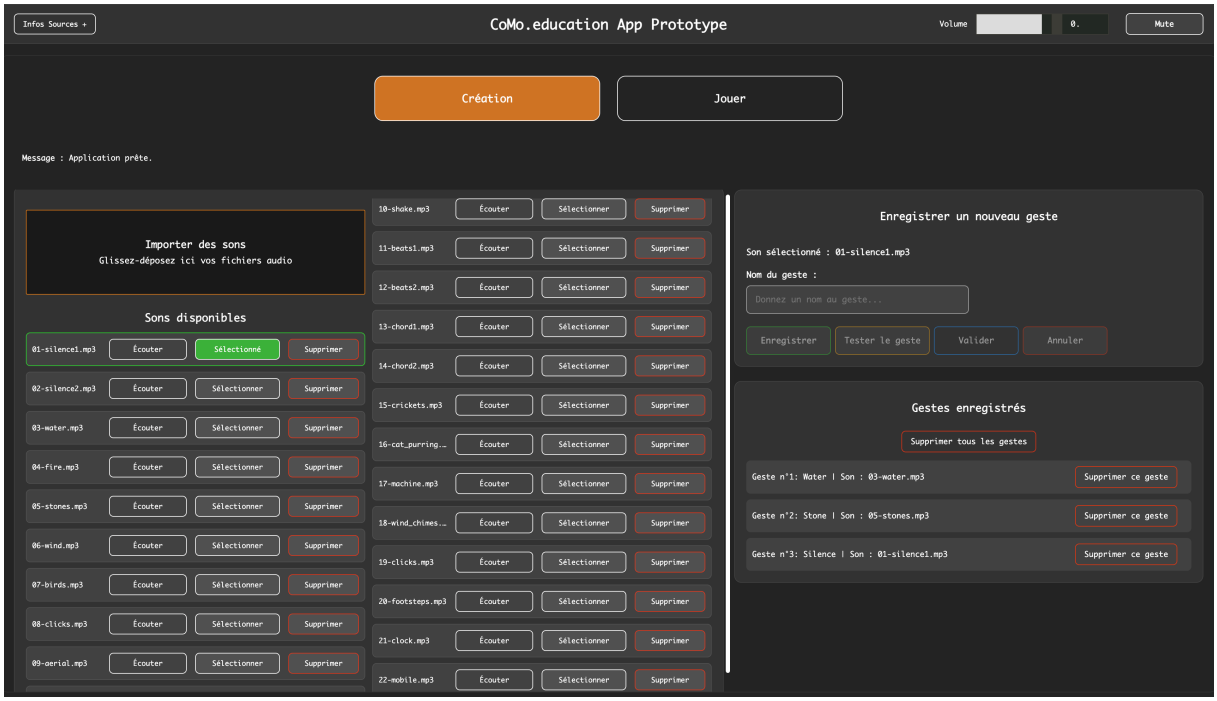


Figure 25: Interface utilisateur de la nouvelle application CoMo.education (ici en mode Création)

Système interactif final. Le système forme un dispositif hybride dans lequel le module embarqué assure à la fois la captation du mouvement et la génération de la réponse sonore (cf. Fig. 26). L'ordinateur et le Raspberry Pi sont connectés au même réseau Wi-Fi local. Le premier exécute le serveur Soundworks et le client web *teacher*, tandis que le second exécute le client

Node.js *device*. Les deux clients établissent chacun une connexion WebSocket avec le serveur, qui transmet les commandes et synchronise les états partagés.

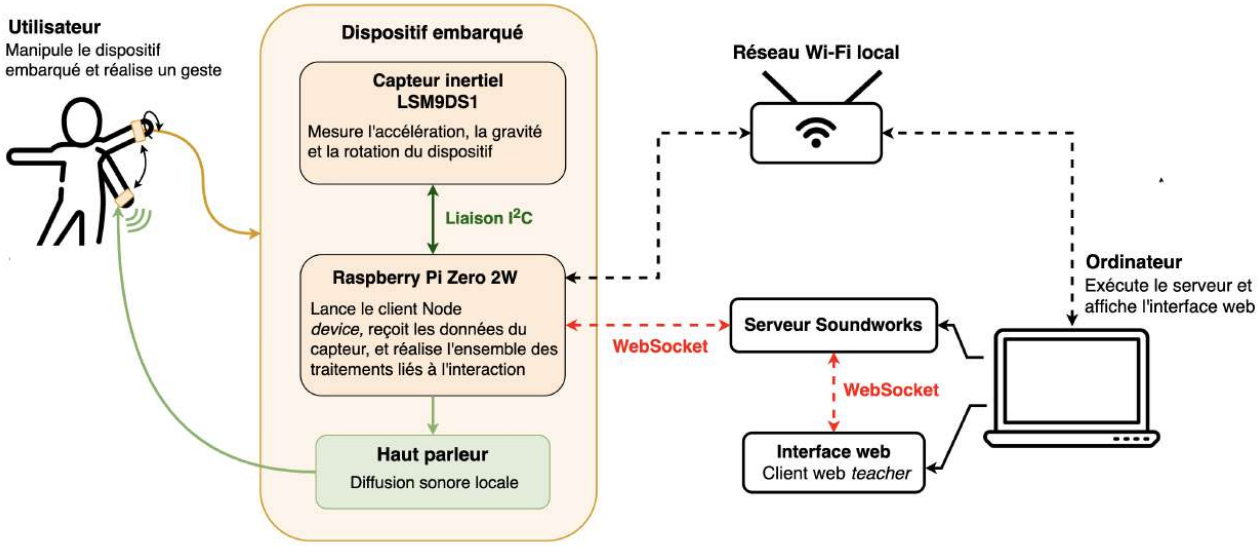


Figure 26: Schéma fonctionnel et composantes principales du système interactif

Pour synthétiser, lorsque l'utilisateur manipule le dispositif, le LSM9DS1 mesure notamment l'accélération et la vitesse angulaire. Le Raspberry Pi acquiert et traite localement ces données, réalise la reconnaissance gestuelle et génère le signal correspondant, ensuite diffusé par les haut-parleurs miniatures. Le réseau intervient donc dans la configuration et la coordination du système, tandis que la captation, la reconnaissance et la production sonore sont effectuées sur le dispositif embarqué.

4.2.3 Retours utilisateurs et travaux futurs

Retours utilisateurs. Une séance de présentation et d'évaluation d'environ une heure et trente minutes a réuni trois chargées de médiation culturelle de l'Ircam et deux chercheurs de l'équipe ISMM, dont le tuteur de stage et le responsable de l'équipe. Les médiatrices, qui conçoivent et animent régulièrement des ateliers CoMo.education, constituaient les principales utilisatrices expertes. L'auteur du rapport a présenté les prototypes, réalisé des démonstrations et animé la discussion à partir de questions ouvertes, tout en répondant aux interrogations techniques. Les chercheurs ont complété les échanges par des pistes d'amélioration et des perspectives d'évolution. Avec l'accord des participants, la séance a été enregistrée puis réécoutée afin d'en dégager les principaux thèmes ; les extraits cités ont été anonymisés.

L'interface a reçu un accueil globalement positif pour sa simplicité, sa lisibilité et l'accès direct aux fonctions. Une participante la décrit comme « une interface qui va droit au but [...] et qui sera facile à prendre en main par les médiateurs/médiatrices ». Le regroupement sur une page unique a été perçu comme un gain de temps par rapport à l'ancienne version, qui imposait davantage de changements de page et de manipulations sur le smartphone. La banque sonore a également été jugée plus facile à parcourir. Les participantes ont néanmoins signalé que quelques indications supplémentaires seraient utiles, particulièrement pour les interfaces dédiées aux utilisateurs non experts.

La principale difficulté observée concernait le déclenchement de l'enregistrement. Dans la version présentée au début de la séance, l'absence de décompte ne fournissait pas de repère précis pour commencer le geste et pouvait introduire une phase indésirable dans l'exemple appris. Comme l'indique l'un des chercheurs, « il faut mettre le compte à rebours, parce que sinon les personnes ne synchronisent pas le départ du geste, et puis ça se retrouve dans la reconnaissance ». Les participantes ont aussi proposé un arrêt automatique afin que l'utilisateur n'ait pas à interrompre son geste pour cliquer sur le bouton d'arrêt. À la suite de l'atelier, un décompte vocal et un arrêt après quatre secondes ont donc été intégrés. Ces modifications clarifient la consigne et limitent la variabilité temporelle des exemples. Le positionnement du capteur au niveau du poignet (plutôt que sur la main) a également été envisagé pour réduire les variations de manipulation, hypothèse qui devra être évaluée en situation afin de déterminer si elle améliore effectivement la reconnaissance sans limiter la liberté de mouvement.

Le principal point critique concerne l'encombrement du prototype, jugé encore trop important pour la main d'un enfant de maternelle (cf. Fig. 27). L'agencement et la protection des modules (cf. Fig. 28) doivent donc être revus avant une utilisation régulière auprès du public visé. Les solutions évoquées comprennent le placement des modules dans une mitaine, un brassard élastique ou une manchette rigide (inspirée des protège-bras utilisés pour le tir à l'arc) portée au poignet ou à l'avant-bras. Elles libéreraient la main, mais introduiraient des contraintes d'ajustement, d'installation et de logistique. Le montage actuel reste en outre vulnérable en cas de chocs au niveau de certaines soudures ; sa structure modulaire facilite néanmoins le remplacement des éléments endommagés par rapport à un smartphone.

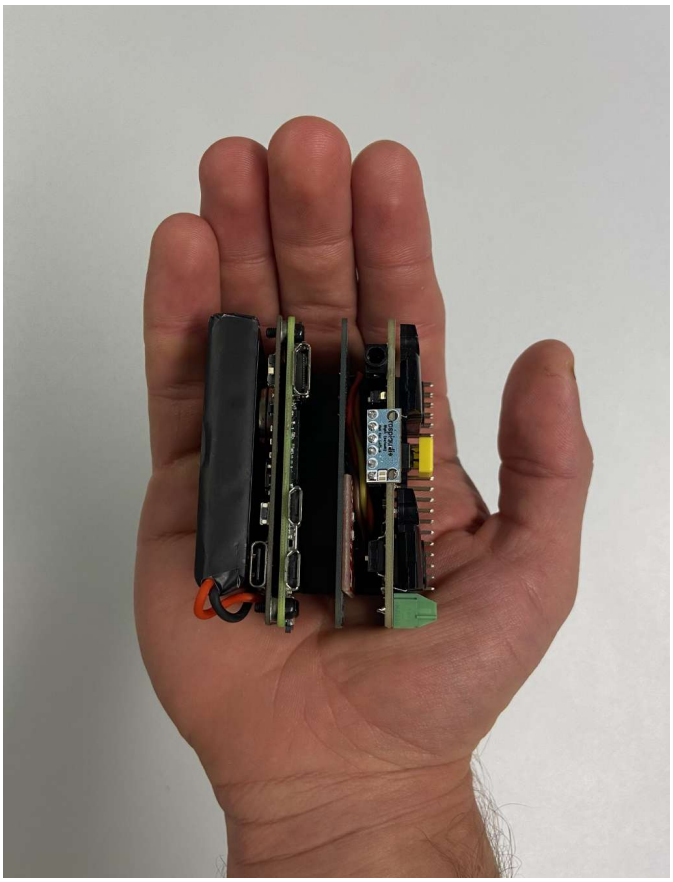


Figure 27: Dispositif embarqué tenu dans la main d'un adulte, mettant en évidence son encombrement

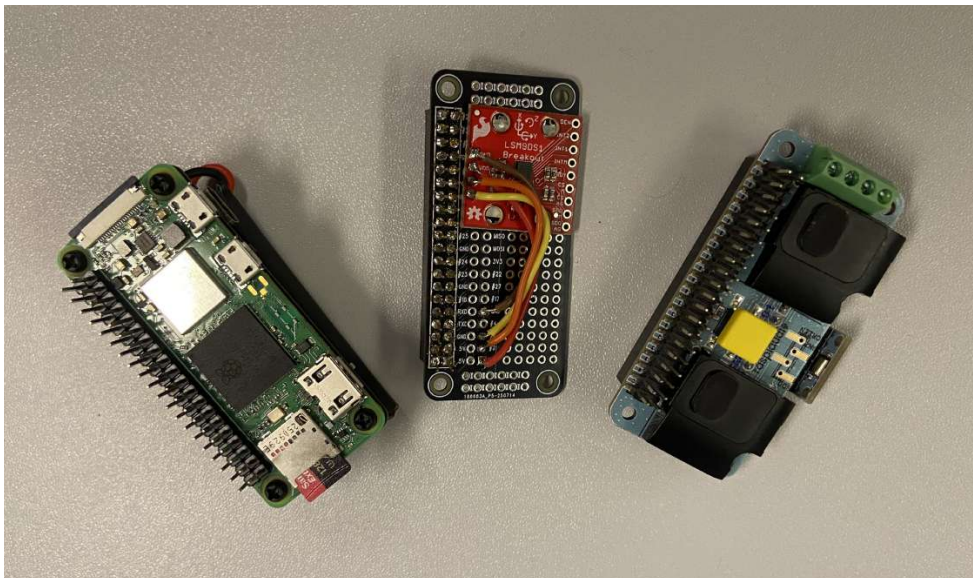


Figure 28: Vue des différents modules matériels séparés qui constituent le dispositif embarqué

La diffusion sonore embarquée a en revanche été considérée comme un progrès par rapport au smartphone. Comme les enfants pouvaient modifier ou couper involontairement le volume du smartphone, l'absence de retour sonore risquait d'interrompre l'activité et de provoquer de la frustration. Le contrôle de la diffusion sonore par le dispositif réduit cette incertitude. Enfin, l'importation dynamique de fichiers audio personnels ouvre de nouvelles possibilités pour l'organisation des ateliers. À long terme, les médiatrices ont mentionné l'idée de réaliser un atelier en plusieurs séances : les enfants pourraient d'abord imaginer une histoire, ses gestes et ses sons, éventuellement enregistrer leurs propres bruitages, puis utiliser le système pour assembler et présenter leur création.

Travaux futurs. Le dispositif et l'application constituent une première version fonctionnelle qui devra être prolongée afin de répondre pleinement aux conditions d'utilisation envisagées pour *CoMo.education*. Les prochaines étapes matérielles concernent la réduction de l'encombrement, la protection des composants et l'étude d'une forme de port confortable et robuste. Les solutions de type mitaine ou manchette devront préserver la liberté de mouvement, s'adapter aux différentes morphologies et rester simples à installer pendant l'atelier.

L'application web devra également gérer plusieurs « histoires » sous la forme de sessions distinctes regroupant les gestes, les exemples et les sons d'une narration. Les utilisateurs pourront ainsi créer, sauvegarder, retrouver et changer de projet sans reconfigurer le système. La diversification des activités nécessitera par ailleurs des interfaces adaptées aux différents rôles : l'interface actuelle pourra rester destinée aux membres du projet et aux personnes chargées de la configuration, tandis que des vues plus simples et guidées pourront être proposées aux médiateurs, enseignants, parents ou participants.

Cette première évaluation reste qualitative et exploratoire, et aucun enfant n'y a directement participé. Une fois le dispositif adapté à son public et les interfaces finalisées, une étude en situation réelle devra donc observer sa prise en main, la qualité de la reconnaissance gestuelle et son intégration dans la dynamique pédagogique et collective de l'atelier.

4.3 Discussion

Le travail réalisé confirme la faisabilité technique de l'intégration d'une nouvelle source de mouvement dans CoMo et de son utilisation dans CoMo.education. Ces résultats doivent toutefois être discutés au regard des limites du protocole, de la représentation des gestes et des finalités pédagogiques du projet.

La première limite concerne le banc de test. Les trois sources ont été solidarisées (les unes sur les autres) et orientées selon des axes cohérents afin de leur appliquer des mouvements aussi similaires que possible, sans pouvoir garantir des sollicitations rigoureusement identiques. Un léger défaut d'alignement modifie la projection des mesures sur chaque axe, tandis qu'une différence de position peut entraîner des accélérations distinctes. Ces facteurs peuvent contribuer aux écarts observés indépendamment des performances des capteurs. En outre, les échantillons n'étant pas acquis aux mêmes instants, les signaux ont été interpolés sur une grille commune. Cette opération rend possible leur comparaison point par point, mais peut légèrement modifier leur représentation. Les résultats caractérisent donc une cohérence relative entre les sources, et non leur exactitude absolue, puisqu'aucun des dispositifs comparés ne constitue une référence métrologique étalonnée.

La reconnaissance gestuelle ne peut par ailleurs être réduite à un taux de réussite. Dans une démarche d'apprentissage automatique interactif, l'utilisateur enregistre des exemples, teste le modèle, observe ou écoute le résultat, puis ajuste ses démonstrations. Ces allers-retours lui permettent de comprendre progressivement ce que le système distingue et de construire des catégories suffisamment robustes pour l'activité [82]. Cette compréhension relève moins d'une connaissance mathématique du modèle que d'un savoir-faire développé par l'interaction. Dans *CoMo.education*, ce processus dépend largement du médiateur ou de l'enseignant, qui choisit les gestes, guide leur réalisation et intervient lorsque la reconnaissance ne produit pas le résultat attendu.

Une difficulté plus fondamentale concerne la définition même du geste. Pour l'utilisateur, un geste ne correspond pas uniquement à un déplacement mesurable : il possède une intention et une signification qui dépendent du contexte dans lequel il est réalisé. Dans CoMo.education, un même mouvement peut ainsi représenter un personnage, une action ou un événement sonore en fonction du récit. Saint-Germier et al. [82] proposent donc une définition centrée sur l'utilisateur, selon laquelle un geste est un mouvement ou une posture que celui-ci reconnaît comme appartenant à une catégorie significative. Cette définition ne coïncide pas nécessairement avec celle que construit le système à partir des données inertielles.

Cette information partielle est encore transformée avant la reconnaissance : les mesures inertielles sont complétées par la gravité et l'intensité, organisées en vecteurs, puis regroupées dans une fenêtre temporelle enregistrée. Le modèle apprend ainsi une représentation construite du geste, déterminée par le capteur, les descripteurs et la délimitation de l'exemple. Une hésitation ou un retour à l'immobilité peut être intégré à la catégorie, tandis qu'une caractéristique importante pour l'utilisateur peut rester invisible si elle concerne une autre partie du corps. Une erreur ne traduit donc pas nécessairement une défaillance de XMM ; elle peut provenir d'un décalage entre la catégorie humaine et sa représentation par la chaîne de captation.

Cette question est particulièrement importante lorsque les exemples sont enregistrés par un adulte puis reproduits par des enfants, dont les amplitudes, les vitesses et les coordinations diffèrent. La généralisation dépend alors du nombre et de la diversité des démonstrations, mais aussi de la façon dont le geste est présenté, imité et compris par le groupe. Il paraît donc

préférable de choisir des catégories suffisamment distinctes et d'enregistrer des exemples variés, sans imposer une standardisation excessive qui limiterait l'expression corporelle.

Ces observations invitent enfin à replacer l'optimisation et la technique dans les objectifs du projet. La fréquence d'acquisition, le jitter, les corrélations et les erreurs de reconnaissance fournissent des indicateurs quantifiables, dont l'analyse et l'optimisation contribuent à assurer un fonctionnement suffisamment stable. Ces améliorations ne garantissent toutefois pas, à elles seules, une meilleure expérience. Une reconnaissance plus précise pourrait exiger des gestes plus standardisés ou une procédure d'apprentissage plus lourde ; inversement, un système imparfait mais prévisible, ajustable et capable de préserver la continuité du récit peut être plus pertinent pour l'atelier.

Le risque serait de faire des indicateurs techniques une finalité, simplement parce qu'ils sont quantifiables et optimisables, alors que *CoMo.education* vise d'abord la narration collective, l'engagement corporel, l'écoute et les interactions sociales. La question n'est alors plus seulement de savoir comment rendre le système techniquement plus performant, mais de définir concrètement ce qui constitue une véritable « amélioration » au regard du projet et de ses objectifs. Dans ce contexte, il nous semble qu'une amélioration n'a de sens que si elle facilite l'activité, limite les interruptions ou étend les possibilités d'appropriation sans imposer de contrainte disproportionnée. La réflexion d'Ivan Illich sur les outils conviviaux [83] offre ici un parallèle prudent : un moyen technique doit rester au service des intentions de ses utilisateurs plutôt que leur imposer sa propre logique. Dans un atelier où les comportements des enfants sont largement imprévisibles, l'optimisation la plus pertinente pourrait ainsi résider autant dans la tolérance aux variations et la facilité d'ajustement du dispositif que dans ses seules performances numériques.

5. Conclusion et perspectives

Ce stage s'est inscrit dans la dynamique d'évolution du framework CoMo, initialement développé autour de l'utilisation de smartphones pour la captation du mouvement et la production sonore. Si ces appareils constituent des solutions accessibles, la diversification des usages de CoMo suppose de pouvoir intégrer d'autres dispositifs, mieux adaptés à certains contextes, sans remettre en cause l'architecture générale des applications. L'objectif principal a donc été de concevoir et d'intégrer une nouvelle source de mouvement dans cet environnement, tout en assurant une représentation commune des données et une cohérence suffisante avec les sources existantes. CoMo.education a ensuite constitué un cas d'usage concret pour expérimenter cette source dans un contexte pédagogique fondé sur la narration, le mouvement et l'interaction sonore collective.

Une démarche progressive et incrémentale a été adoptée pour atteindre cet objectif. Le travail a d'abord porté sur la prise en main du capteur inertiel LSM9DS1 et sur l'acquisition de ses données en dehors de CoMo. L'acquisition a ensuite été intégrée au framework sous la forme d'une nouvelle source de mouvement dont les trames respectent le format commun utilisé dans cet environnement. Les données ont ainsi été rendues accessibles aux différents composants de CoMo, notamment pour leur visualisation, leur enregistrement, la reconnaissance gestuelle et le contrôle sonore. La source a ensuite été caractérisée et comparée à un R-IoT et à un smartphone utilisant CoMote, avant d'être intégrée avec un Raspberry Pi Zero 2 W, une batterie et un système de diffusion sonore. Enfin, l'application CoMo.education a été entièrement redéveloppée pour accueillir ce nouveau dispositif et répondre aux besoins actuels du projet.

La caractérisation expérimentale a porté sur la stabilité temporelle de l'acquisition et sur la cohérence relative des données inertielles. L'implémentation initiale du LSM9DS1 présentait une irrégularité importante, particulièrement pour une période demandée de 10 ms. La séparation de l'acquisition dans un thread de travail et l'utilisation d'une planification fondée sur des échéances temporelles ont nettement amélioré ce comportement. À 100 Hz, la période moyenne est ainsi passée de 10,79 à 10,00 ms et le jitter absolu moyen de 2,25 à 0,97 ms. Selon l'intervalle considéré, la diminution du jitter atteint entre 46 et 62 %, tandis que les retards extrêmes ont également été fortement réduits. Des irrégularités ponctuelles persistent, mais le comportement temporel du LSM9DS1 devient comparable à celui des sources déjà employées dans CoMo.

La comparaison des données inertielles conduit à un constat similaire. Dans l'ensemble des séquences en mouvement, les coefficients de corrélation mesurés entre les trois sources sont compris entre 0,914 et 0,998. Les dispositifs reproduisent donc de manière cohérente la dynamique générale des gestes, avec une correspondance particulièrement forte entre le LSM9DS1 et le R-IoT. Les mesures gyroscopiques apparaissent globalement plus homogènes que les mesures d'accélération, pour lesquelles des différences d'amplitude et des écarts ponctuels plus importants subsistent. Ces différences ne constituent toutefois pas nécessairement une incohérence : des signaux peuvent évoluer de manière similaire sans fournir des valeurs instantanées identiques. En l'absence d'une référence métrologique étalonnée, les résultats ne permettent pas d'établir l'exactitude absolue des dispositifs. Ils montrent néanmoins que le LSM9DS1 produit des données temporellement exploitables et suffisamment cohérentes avec les sources existantes pour s'intégrer aux usages interactifs visés.

Le dispositif obtenu assure localement l'acquisition des données, leur traitement, la reconnaissance des gestes ainsi que la génération et la diffusion des réponses sonores. L'ordinateur

conserve un rôle de configuration et de contrôle par l'intermédiaire de l'interface web et du serveur Soundworks, auxquels le dispositif est relié par le réseau Wi-Fi local. Cette architecture dissocie ainsi l'interface de contrôle du dispositif manipulé par l'utilisateur, tout en assurant leur coordination à l'aide des états partagés. Le prototype constitue de ce fait une alternative fonctionnelle au smartphone : il réunit la captation du mouvement et la diffusion sonore dans un objet dédié, sans écran ni fonctionnalités susceptibles de détourner l'attention de l'activité.

Le redéveloppement de CoMo.education représente la seconde contribution majeure du stage. La nouvelle application reprend la boucle centrale d'apprentissage automatique interactif : l'utilisateur choisit un son, nomme et enregistre un geste, teste sa reconnaissance, puis valide l'exemple ou recommence son enregistrement avant de jouer avec les associations créées. Elle intègre le modèle XMM, une estimation de l'intensité du mouvement et un mécanisme de stabilisation limitant les changements sonores intempestifs. L'interface réunit les principales fonctions sur une page unique et permet désormais d'importer des sons personnels, ouvrant la possibilité d'étendre l'activité à la création sonore. À la suite de l'atelier d'évaluation, un décompte vocal et un arrêt automatique après quatre secondes ont également été ajoutés afin de fournir un repère commun et de mieux délimiter les exemples d'apprentissage.

Les retours recueillis auprès des chargées de médiation culturelle et des chercheurs de l'équipe ISMM ont apporté une première validation qualitative de ces choix. La simplicité de l'interface, son organisation sur une seule page, l'accès direct à la banque de sons et la diffusion sonore embarquée ont été perçus positivement. Ces échanges ont cependant confirmé la principale limite actuelle du prototype : son encombrement reste trop important pour une utilisation confortable par des enfants de maternelle. Cette évaluation demeure par ailleurs exploratoire, puisqu'aucun enfant n'y a directement participé. Elle renseigne donc sur le point de vue de professionnelles connaissant précisément les ateliers, mais ne permet pas encore de conclure sur l'appropriation effective du dispositif par son public final. Le système doit ainsi être considéré comme une preuve de faisabilité technique et fonctionnelle plutôt que comme un produit finalisé.

Les prochaines étapes concerneront en priorité l'intégration matérielle. Il sera nécessaire de réduire l'encombrement, de mieux protéger les composants et d'étudier une forme de port adaptée aux mouvements et à la morphologie des enfants. Les solutions envisagées, telles qu'une mitaine ou une manchette placée au niveau du poignet ou de l'avant-bras, devront être évaluées en matière de confort, de liberté de mouvement, de robustesse, de facilité d'installation et de maintenance. L'objectif ne sera donc pas seulement de miniaturiser le dispositif, mais de transformer l'assemblage actuel en un objet cohérent avec les capacités des enfants et les contraintes d'un atelier.

L'application devra également évoluer vers une gestion complète des histoires sous la forme de sessions distinctes, regroupant les gestes, les exemples d'apprentissage, les sons et leurs associations. Cette organisation permettra de créer, sauvegarder et retrouver plusieurs histoires sans reconfigurer manuellement le système. La diversification des activités nécessitera aussi des interfaces adaptées aux différents rôles : l'interface actuelle pourra être conservée pour les membres du projet et les personnes chargées de la configuration, tandis que des vues plus simples et guidées pourront être proposées aux médiateurs, aux enseignants, aux parents ou aux participants. Leur adaptation à différents formats d'écran et terminaux mobiles devra être étudiée dans cette même perspective. Une nouvelle évaluation devra enfin être conduite en situation réelle avec des enfants. Elle permettra d'examiner la prise en main du dispositif, la compréhension des consignes, la qualité de la reconnaissance et son intégration dans la dynamique collective de l'atelier. Elle devra notamment tenir compte du fait qu'un geste enregistré par un adulte peut être exécuté différemment par un enfant. L'amélioration de la reconnaissance reposera ainsi au-

tant sur la diversité des exemples, leur délimitation temporelle et le choix de gestes suffisamment distincts que sur l'optimisation du modèle lui-même.

Les conclusions tirées du cas de CoMo.education ne doivent toutefois pas être généralisées sans précaution à tous les usages possibles du dispositif. Un contexte pédagogique, artistique, scientifique ou thérapeutique implique des attentes et des critères d'évaluation différents. De futurs travaux pourront ainsi expérimenter cette source dans d'autres projets développés avec CoMo, notamment dans le domaine de la sonification du mouvement pour la rééducation, et conduire à reconsidérer certains choix matériels ou logiciels.

En définitive, ce travail a permis de construire une chaîne complète d'interaction, depuis la mesure inertielle jusqu'à la diffusion sonore, et de l'inscrire dans un environnement web distribué existant. Il montre également que la qualité d'un tel système ne peut être réduite à ses seules performances numériques. La stabilité temporelle, la cohérence des données et la qualité de la reconnaissance sont nécessaires pour rendre l'outil fiable, mais elles ne constituent pas sa finalité. Dans CoMo.education, la technique prend véritablement sens lorsqu'elle devient suffisamment stable, lisible et adaptable pour soutenir la narration collective, l'engagement corporel et les interactions entre les enfants et les personnes qui les accompagnent. La poursuite du projet consistera donc moins à rechercher une perfection technique abstraite qu'à concevoir un dispositif capable de s'effacer au profit de l'expérience qu'il rend possible.

Références bibliographiques

[1] M. Weiser, "The Computer for the 21st Century," in *Scientific American*, vol. 265, no. 3, p. 94, Sept. 1991.

[2] D. Miorandi, S. Sicari, F. De Pellegrini, and I. Chlamtac, "Internet of things: Vision, applications and research challenges," in *Ad Hoc Networks*, vol. 10, no. 7, pp. 1497–1516, 2012, doi: https://doi.org/10.1016/j.adhoc.2012.02.016.

[3] L. Atzori, A. Iera, and G. Morabito, "The internet of things: a survey," in *Computer networks*, vol. 54, no. 15, pp. 2787–2805, 2010, doi: https://doi.org/10.1016/j.comnet.2010.05.010.

[4] B. Matuszewski, and F. Bevilacqua, "Toward a Web of Audio Things," in *Sound and Music Computing Conference*, Limassol, Cyprus, Jul. 2018. https://hal.science/hal-01874968/file/2018-SMC%20-%20Toward%20a%20Web%20of%20Audio%20Things.pdf.

[5] L. Turchet *et al.*, "The Internet of Sounds: Convergent Trends, Insights and Future Directions," in *IEEE Internet of Things Journal*, 2023, doi: https://doi.org/10.1109/jiot.2023.3253602.

[6] A. Golvet, "Systèmes musicaux distribués : concevoir des outils web pour la recherche et la pratique artistique", Human-Computer Interaction [cs.HC], Sorbonne Université, 2024. https://theses.hal.science/tel-05092751v1/document.

[7] L. Turchet, C. Fischione, G. Essl, D. Keller, and M. Barthet, "Internet of Musical Things: Vision and Challenges," in *IEEE Access*, vol. 6, pp. 61994–62017, 2018, doi: https://doi.org/10.1109/ACCESS.2018.2872625.

[8] B. Matuszewski, "A Web-Based Framework for Distributed Music System Research and Creation," in *AES-Journal of the Audio Engineering Society*, vol. 68, no. 10, pp. 717-726, Oct. 2020, doi: https://doi.org/10.17743/jaes.2020.0015.

[9] B. Matuszewski, "Systèmes Musicaux Distribués et Technologies Web : Motivations, Design et Implémentation d'un Système Expérimental", PhD thesis, Paris, France, Université Paris 8, 2020.

[10] M. M. Wanderley and P. Depalle, "Gestural control of sound synthesis," in *Proceeding of the IEEE*, vol. 92, no. 4, pp. 632-644, April 2004, doi: https://doi.org/10.1109/JPROC.2004.825882.

[11] A. O. Effenberg, "Movement sonification: Effects on perception and action," in *IEEE MultiMedia*, vol. 12, no. 2, pp. 53–59, April-June 2005, doi: https://doi.org/10.1109/MMUL.2005.31.

[12] S. Saint-Cast, B. Matuszewski, and F. Bevilacqua, "A Full-Stack Web-Based Ecosystem for Movement–Sound Interactions," *Proceedings of International Conference on Movement and Computing (MOCO'26)*, ACM, New York, NY, USA, 2025.

[13] P. Dourish, "The Appropriation of Interactive Technologies: Some Lessons from Placeless Documents," in *Computer Supported Cooperative Work* (CSCW), vol. 12, no. 4, pp. 465-490, Dec. 2003, doi: https://doi.org/10.1023/A:1026149119426.

[14] R. Fiebrink, P.R. Cook, "The Wekinator: A System for Real-time, Interactive Machine Learning in Music", 2010.

[15] R. Fiebrink, D. Trueman, and P.R. Cook, "A Meta-Instrument for Interactive, On-the-Fly Machine Learning," in *New Interfaces for Musical Expression*, 2009.

[16] M. Voillot, B. Matuszewski, J. Chevrier, and F. Bevilacqua, "CoMo.education: Collective and embodied storytelling in kindergarten using a gesture-sound interactive system," in *9th International Conference on Movement and Computing (MOCO'24)*, Utrecht Netherlands. ACM, New York, NY, USA, 2024, doi: https://doi.org/10.1145/3658852.3659070.

[17] N. Schnell, et al., "Collective Loops: Multimodal Interactions Through Co-located Mobile Devices and Synchronized Audiovisual Rendering Based on Web Standards," in *Proceedings of the Eleventh International Conference on Tangible, Embedded, and Embodied Interaction*, pp. 217-224, 2017, doi: https://doi.org/10.1145/3024969.3024972.

[18] N. Cross, "Designerly ways of knowing," in *Design Studies*, vol. 3, no 4, pp. 221- 227, Oct. 1982.

[19] A. Findeli, D. Brouillet, S. Martin, C. Moineau and R. Tarrago, "Research through Design and Transciplinarity: A Tentative Contribution to the Methodology of Design Research," in *Swiss Design Network Symposium*, Bern, Switzerland, 2008.

[20] A. Findeli, "La recherche-projet en design et la question de la question de recherche : essai de clarification conceptuelle," in *Sciences du Design*, no. 1, pp. 45-57, 2015.

[21] B. Matuszewski, and F. Bevilacqua, "Composed epistemologies - A case from computer music research," in *Undone Computer Science*, Nantes, France, Feb. 2024. https://hal.science/hal-04451057/document.

[22] W. W. Gaver, P. Gall Krogh, A. Boucher, and D. Chatting. 2022, "Emergence as a Feature of Practice-based Design Research," in *Designing Interactive Systems Conference (DIS '22), June 13–1, 2022, Virtual Event, Australia*, ACM, New York, NY, USA, 2002, doi: https://doi.org/10.1145/3532106.3533524.

[23] P. Tchounikine, (2017) "Designing for Appropriation: A Theoretical Account," in *Human–Computer Interaction*, vol. 32, no. 4, pp. 155-195, 2017, doi: https://doi.org/10.1080/07370024.2016.1203263.

[24] J. D. Gould, and C. Lewis, "Designing for Usability: Key Principles and What Designers Think", in *Human Aspect of Computing*, ACM, vol 28, no. 3, March 1985.

[25] V. Braun, and V. Clarke, "Using thematic analysis in psychology," in *Qualitative Research in Psychology*, vol. 3, no. 2, pp. 77-101, 2006, doi: https://doi.org/10.1191/1478088706qp063oa.

[26] L. Turchet, G. Fazekas, M. Lagrange, H. S. Ghadikolaei and C. Fischione, "The Internet of Audio Things: State of the Art, Vision, and Challenges," in *IEEE Internet of Things Journal*, vol. 7, no. 10, pp.10233-10249, Oct. 2020, doi: https://doi.org/10.1109/JIOT.2020.2997047.

[27] L. Turchet, "Smart Musical Instruments: Vision, Design Principles, and Future Directions," in *IEEE Access*, vol. 7, pp. 8944-8963, 2019, doi: https://doi.org/10.1109/ACCESS.2018.2876891.

[28] L. Turchet, A. McPherson, and C. Fischione, "Smart instruments: Towards an ecosystem of interoperable devices connecting performers and audiences," in *Proceedings of Sound and Music Computing Conference*, pp. 498–505, 2016.

[29] K. Ng, "Sensing and mapping for interactive performance," in *Organised Sound*, vol. 7, pp 191-200, 2002, doi: https://doi.org/10.1017/S1355771802002091.

[30] C. Rottondi, C. Chafe, C. Allocchio, and A. Sarti, "An overview on networked music performance technologies," in *IEEE Access*, vol. 4, pp. 8823–8843, 2016, doi: https://doi.org/10.1109/ACCESS.2016.2628440.

[31] A. Bertrand, "Applications and trends in wireless acoustic sensor networks: A signal processing perspective," in *18th IEEE symposium on communications and vehicular technology in the Benelux (SCVT)*, pp.1-6, 2011, doi: https://doi.org/10.1109/SCVT.2011.6101302.

[32] A. Tajadura-Jiménez, M. Basia, O. Deroy, M. Fairhurst, N. Marquardt, and N. Bianchi-Berthouze, "As Light as your Footsteps: Altering Walking Sounds to Change Perceived Body Weight, Emotional State and Gait," in *Proceedings of the 33rd Annual ACM Conference on Human Factors in Computing Systems (CHI '15)*. Association for Computing Machinery, New York, NY, USA, pp. 2943–2952, 2015, doi:https://doi.org/10.1145/2702123.2702374

[33] L. Turchet, "Interactive sonification and the iot: the case of smart sonic shoes for clinical applications," in *Proceedings of Audio Mostly Conference (AM'19), September 18–20, 2019, Nottingham, United Kingdom*, ACM, New York, NY, USA 2019, doi: https://doi.org/10.1145/3356590.3356631.

[34] S. Skach, A. Xamb´o, L. Turchet, A. Stolfi, R. Stewart, and M. Barthet, "Embodied interactions with e-textiles and the internet of sounds for performing arts," in *Proceedings of the International Conference on Tangible, Embedded, and Embodied Interaction*. ACM, pp. 80–87, 2018, doi: https://doi.org/10.1145/3173225.3173272.

[35] T. Hermann, and A. Hunt, "An introduction to interactive sonification," in *IEEE Multimedia*. pp. 20-24, 2005, doi: https://doi.org/10.1109/MMUL.2005.26.

[36] B. Smus, *Web Audio API: Advanced Sound for Games and Interactive Apps*. O'Reilly Media, Inc., 2013.

[37] J. D. Reiss, *Working with the Web Audio API*, 1st edition, Focal Press, April 2022.

[38] B. Matuszewski, and O. Rottier, "The Web Audio API as a Standardized Interface Beyond Web Browsers," in *Journal of the Audio Engineering Society*, vol. 71, no. 11, pp. 790-801, Nov. 2023, doi: https://doi.org/10.17743/jaes.2022.0114.

[39] O. Rottier, and B. Matuszewski, "A Rust Implementation of the Web Audio API," *Proceedings of the 7th Web Audio Conference*, Cannes, France, 2022, doi: https://zenodo.org/records/6767674.

[40] D. Guinard and V. Trifa, *Building the Web of Things*, 1st edition, Greenwich, CT, USA: Manning Publications Co., 2016.

[41] L. Wyse, "Spatially distributed sound computing and rendering using the web audio platform", in *Proceedings of the 1rst Web Audio Conference*, WAC, Paris, France 2015.

[42] B. Matuszewski, N. Schnell, F. Bevilacqua, "Interaction Topologies in Mobile-Based Situated Networked Music Systems," in *Wireless Communications and Mobile Computing*, 9142490, 9 pages, 2019, doi: https://doi.org/10.1155/2019/9142490.

[43] F. Bevilacqua, B. Matuszewski, G. Paine, N. Schnell, "On Designing, Composing and Performing Networked Collective Interactions," in *Organised Sound*, vol. 26, no.3, pp. 333-339, 2021, doi: https://doi.org/10.1017/S135577182100042X.

[44] N. Schnell, S. Robaszkiewicz, F. Bevilacqua, and D. Schwarz. "Collective Sound Checks: Exploring Intertwined Sonic and Social Affordances of Mobile Web Applications," in *Proceedings of the Ninth International Conference on Tangible, Embedded, and Embodied Interaction*. ACM, pp. 685–690, 2015.

[45] D. Poirier-Quinot, B. Matuszewski, N. Schnell, O. Warusfel, "Nü Soundworks : using spectators smartphones as a distributed network of speakers and sensors during live performances," in *Web Audio Conference*, Center For Digital Music - Queen Mary University of London, Aug. 2017. hal-01574171

[46] M. Van Steen, and A. S. Tanenbaum, "A brief introduction to distributed systems," in *Computing*, vol. 98, no. 10, pp. 967-1009, 2016, doi: https://doi.org/10.1007/s00607-016-0508-7.

[47] B. Matuszewski, "Soundworks - A Framework for Networked Music Systems on the Web - State of Affairs and New Developments," in *Proceedings of the Web Audio Conference* (WAC) 2019, Trondheim, Norway, Dec. 2019. https://hal.science/hal-02387783v1/document.

[48] B. Matuszewski, and A. Golvet, "Rapid Prototyping of Distributed Musical Things using Web Technologies," in *4th International Symposium on the Internet of Sounds*, Pisa, Italy, pp. 1–5, Oct. 2023, doi: https://doi.org/10.1109/IEEECONF59510.2023.10335368.

[49] T. Denez, A. Beaufort, and C. Verron, "Designing a Geolocated Soundwalk Player Using DIY Electronics: An Underestimated Approach to Site-specific Sound Art and Research" in *Proceedings of the 17th International Symposium on Computer Music Multidisciplinary Research*, pp. 859–870, 2025, doi: https://doi.org/10.5281/zenodo.17502449

[50] F. Bevilacqua, et al., "Sensori-Motor Learning with Movement Sonification: Perspectives from Recent Interdisciplinary Studies," in *Frontiers in Neuroscience*, vol. 10, pp.385, 2016, doi: https://doi.org/10.3389/fnins.2016.00385.

[51] A. Giomi, "Somatic Sonification in Dance Performances. From the Artistic to the Perceptual and Back," in *Proceedings of the 7th International Conference on Movement and Computing*, ACM, Jersey City/Virtual NJ USA, pp. 1-8, 2020, doi: https://doi.org/10.1145/3401956.3404226.

[52] M. Mainsbridge, *Body as Instrument: Performing with Gestural Systems in Live Electronic Music*, Bloomsbury Publishing USA, 2022.

[53] A. Tajadura-Jiménez, A. Väljamäe, F. Bevilacqua, and N. Bianchi-Berthouze, "Principles for Designing Body-Centered Auditory Feedback," in *The Wiley Handbook of Human Computer Interaction, (eds K.L. Norman and J. Kirakowski)*, pp. 371–403, 2018 doi: https://doi.org/10.1002/9781118976005.

[54] V. van Rheden, T. Grah, and A. Meschtscherjakov, "Sonification approaches in sports in the past decade: a literature review," in *Proceedings of the 15th International Audio Mostly Conference*, pp. 199–205, 2020.

[55] M. M. Wanderley, and P Depalle, "Gestural control of sound synthesis," in *Proceeding of IEEE*, vol. 92, no. 4, pp. 632–644, 2004, doi: https://doi.org/10.1109/JPROC.2004.825882.

[56] I. Peyre, "Sonification du mouvement pour la rééducation après une lésion cérébrale acquise : conception et évaluations de dispositifs", Interface homme-machine [cs.HC]. Sorbonne Université, 2022.

[57] A. Tanaka, "Embodied Musical Interaction," in *New Directions in Music and Human-Computer Interaction*, S. Holland, T. Mudd, K. Wilkie-McKenna, A. McPherson, and M.M. Wanderley (eds.), Springer Series on Cultural Computing, Springer, pp. 135–154, 2019. doi: https://doi.org/10.1007/978-3-319-92069-6_9

[58] E. Fléty, and F. Bevilacqua, "Wireless Inertial Measurement Units in Performing Arts," in *Sensors (Basel, Switzerland)*, 2025, vol. 25, no. 19, pp. 6188, Oct. 2025, doi: https://doi.org/10.3390/s25196188.

[59] E. Miranda and M. Wanderley, *New Digital Musical Instruments: Control and Interaction beyond the Keyboard*, A-R Editions, 2006.

[60] M. Donnarumma. "On biophysical music," in *Guide to Unconventional Computing for Music*, Springer, pp. 63–83, 2017.

[61] F. Behrendt, "Telephones, music and history: From the invention era to the early smartphone days," in *Convergence: The International Journal of Research into New Media Technologies*, vol. 27, no. 6, pp. 1678–1695, Dec. 2021, doi: https://doi.org/10.1177/13548565211028810.

[62] M. A. Duarte-García, E. Wilde, R. Cortez-Madrigal, and J. R. Sigal-Sefchovich, "The use of an interactive music system as an aid for exploring sound in music education in a rural area," in *Revista Musica*, vol. 20, no. 1, pp. 357-380, 2020, doi: https://doi.org/10.11606/rm.v20i1.170736.

[63] A. Alessandro,"Designing From Listening: Embodied Experience and Sonic Interactions", Doctoral thesis, Goldsmiths, University of London, 2018.

[64] B. Caramiaux, A. Altavilla, S. G. Pobiner, A. Tanakain, "Form Follows Sound: Designing Interactions from Sonic Memories" in *Proceedings of the 33rd Annual ACM Conference on Human Factors in Computing Systems (CHI '15)*, Association for Computing Machinery, New York, NY, USA, pp. 3943–3952, 2015, doi: https://doi.org/10.1145/2702123.2702515.

[65] B. Caramiaux, A. Altavilla, J. Françoise, and F. Bevilacqua, "Gestural Sound Toolkit: Reflections on an Interactive Design Project", in *NIME 2022, Auckland, New Zealand*, 2022. https://hal.science/hal-03800322v1/file/nime2022_gst.pdf.

[66] J. Françoise, and F. Bevilacqua. "Motion-Sound Mapping through Interaction: An Approach to User-Centered Design of Auditory Feedback Using Machine Learning," in *ACM Transactions on Interactive Intelligent Systems (TiiS)*, vol. 8, no. 2, June 2018, doi: https://doi.org/10.1145/3211826.

[67] B. Matuszewski, J. Larralde, and F. Bevilacqua, "Designing movement driven audio applications using a web-based interactive machine learning toolkit," in *Web Audio Conference, (WAC)*, 2018.

[68] T. Hermann, A. Hunt, and J. G. Neuhoff, *The sonification handbook*, Logos Verlag Berlin, Germany, 2011.

[69] G. Kramer, et al., "The sonification report: Status of the field and research agenda. report prepared for the national science foundation by members of the international community for auditory display," in *International Community for Auditory Display (ICAD)*, Santa Fe, NM, 1999.

[70] T. Hermann and A. Hunt, "Guest editors' introduction: An introduction to interactive sonification," in *IEEE Multimedia*, vol. 12, no. 2, pp. 20–24, 2005.

[71] A.O. Effenberg, "Movement Sonification : Effects on Perception and Action," in *IEEE Multimedia*, vol. 12, no. 2, pp. 53-59, 2005, doi: https://doi.org/10.1109/MMUL.2005.31.

[72] N. Schaffert, T. B. Janzen, K. Mattes, and M. H. Thaut, "A Review on the Relationship Between Sound and Movement in Sports and Rehabilitation," in *Frontiers in Psychology*, vol. 10, Article 244, 2019, doi: https://doi.org/10.3389/fpsyg.2019.00244.

[73] J.Ley-Flores, L. Turmo Vidal, N. Berthouze, A. Singh, F. Bevilacqua, and A. Tajadura-Jiménez, "SoniBand: Understanding the Effects of Metaphorical Movement Sonifications on Body Perception and Physical Activity," *in CHI '21: CHI Conference on Human Factors in Computing Systems*, Yokohama (virtual), Japan, pp. 1-16, May 2021, doi: https://doi.org/10.1145/3411764.3445558.

[74] L. Mercier, I. Peyre, C. Vincent, B. Matuszewski, N. Misdariis, and F. Bevilacqua, "La sonification du mouvement : un outil d'aide au développement de la représentation du corps dans l'espace," in *XXXIe congrès de la SOFPEL*, Bordeaux, France, Dec. 2025, hal-05469265.

[75] J. Francoise, N. Schnell, R. Borghesi, and F. Bevilacqua, "Probabilistic Models for Designing Motion and Sound Relationships," in *Proceedings of the 2014 International Conference on New Interfaces for Musical Expression*, NIME'14, London, UK, 2014.

[76] A. Golvet, B. Matuszewski, and F. Bevilacqua, "SIMONE : un instrument distribué pour l'improvisation musicale," in *Revue Francophone d'Informatique et Musique*, no. 10, 2024, doi: https://doi.org/10.56698/rfim.766.

[77] E. Fléty, "Apports de l'électronique pour l'interaction gestuelle: Application au spectacle vivant et à la conception de la lutherie numérique", Musique, musicologie et arts de la scène. Conservatoire national des arts et métiers- CNAM, 2025, Français. https://theses.hal.science/tel-05486307v1.

[78] J. A. Fails and D. R. Olsen, "Interactive machine learning," in *Proceedings of the 8th international conference on Intelligent user interfaces (IUI '03)*, Association for Computing Machinery, New York, NY, USA, pp. 39–45, 2003, doi: https://doi.org/10.1145/604045.604056.

[79] J. J. Dudley and P. O. Kristensson, 2018 "A Review of User Interface Design for Interactive Machine Learning," in *ACM Transactions on Interactive Intelligent Systems (TiiS)*, Vol. 8, Issue 2, Article 8, June 2018, doi: https://doi.org/10.1145/3185517.

[80] J. Françoise, N. Schnell, and F. Bevilacqua, "A Multimodal Probabilistic Model for Gesture-based Control of Sound Synthesis," in *Proceeding of the 21st ACM international conference on Multimedia (MM'13)*, Barcelona, Spain, Association for Computing Machinery, New York, NY, USA, pp.705-708, Oct. 2013, doi: https://doi.org/10.1145/2502081.2502184.

[81] J. Françoise, N. Schnell, R. Borghesi, and F. Bevilacqua, "Probabilistic Models for Designing Motion and Sound Relationships," in *Proceedings of the International Conference on New Interfaces for Musical Expression*, pp. 287-292, 2014, doi: https://doi.org/10.5281/zenodo.1178764.

[82] P. Saint-Germier, B. Matuszewski and F. Bevilacqua, "Machine Learning, Understanding, and Interaction," in *Undone Computer Science*, Philosophia Scientiæ, vol. 30, cahier 2, 2026, doi: https://doi.org/10.4000/16953.

[83] I. Illich, *La convivialité*. 1973.

ANNEXES

Annexe 1 : Dépôts GitHub des applications web développées durant le stage

- Application principale : CoMo.education

Dépôt GitHub : https://github.com/Oneiro31/CoMo.education---Prototype-

- Application pour l'acquisition et l'enregistrement simultané des données

Dépôt GitHub : https://github.com/Oneiro31/CoMo-LSM9DS1-Test

Annexe 2 : Exemple d'une trame complète enregistrée suite à l'acquisition d'une frame de données inertielles de la source LSM9DS1


```
{
    "time":5.510823435999999,
    "index":0,

    "frame": [
        {
            "source":"lsm9ds1",
            "api":"v3",
            "id":"lsm9ds1",
            "timestamp":3759.168905,

            "accelerometer": {
                "x":-1.05559524,
                "y":-0.16276752,
                "z":9.749295720000001,
                "timestamp":3759.168905,
                "frequency":100
            },


            "gyroscope": {
                "x":0.04642575810304917,
                "y":-0.07452555906015788,
                "z":0.05375614096142535,
                "timestamp":3759.168905,
                "frequency":100
            },


            "magnetometer": {
                "x":168.087,
                "y":-1409.024,
                "z":-266.16999999999996,
                "timestamp":3759.168905,
                "frequency":100
            },


            "gravity": {
                "x":-1.0554901170514819,
                "y":-0.16275131056576136,
                "z":9.748324822563914
            }
        }
    ]
}
```


Figure 29: Exemple d'une trame enregistrée suite à l'acquisition d'une frame de données inertielles de la source LSM9DS1

Annexe 3 : Résultats concernant la période d'acquisition, avant l'optimisation temporelle du LSM9DS1

Note : Les informations de ce tableau concordent avec les résultats du jitter présentés dans le Tableau 2.

Intervalle (ms)	**Source**	**Période moyenne (ms)**	**Fréquence moyenne (Hz)**	**Période max. (ms)**	**Période min. (ms)**
10	LSM9DS1	**10,79**	**92,61**	**276,13**	**0,68**
	CoMote	10,20	98,04	171,00	1,00
	R-IoT	10,00	99,99	77,87	0,83
20	LSM9DS1	20,34	49,14	107,25	1,06
	CoMote	20,23	49,40	75,00	1,00
	R-IoT	20,00	49,99	137,83	4,61
40	LSM9DS1	40,27	24,82	86,57	4,61
	CoMote	40,20	24,87	68,00	12,00
	R-IoT	40,05	24,96	86,14	1,80

Tableau 6: Comparaison des résultats liés à la période d'acquisition selon la source et l'intervalle d'échantillonnage, avant l'optimisation temporelle du LSM9DS1

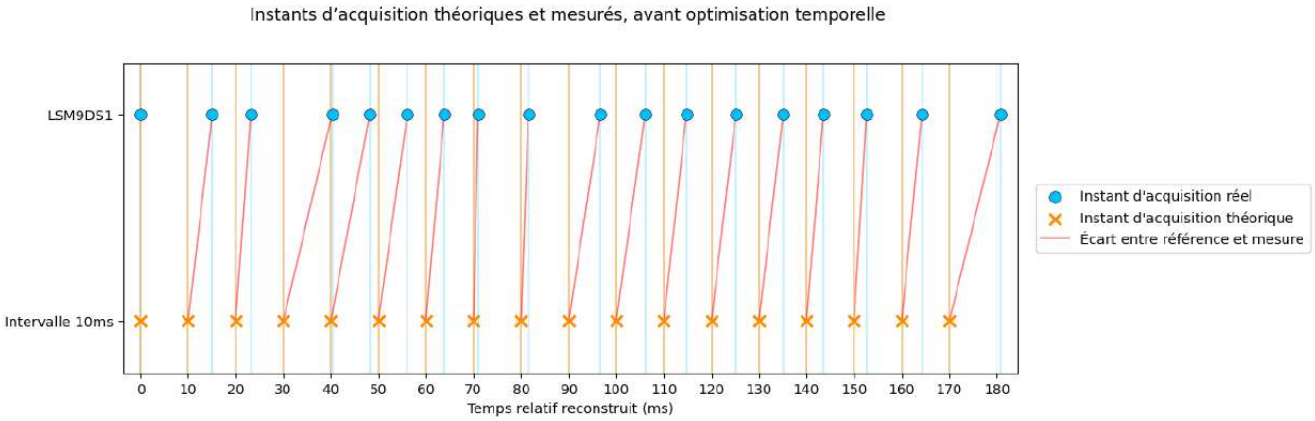
Annexe 4 : Résultats concernant la période d'acquisition, après l'optimisation temporelle du LSM9DS1

Note : Les informations de ce tableau concordent avec les résultats du jitter présentés dans le Tableau 3.

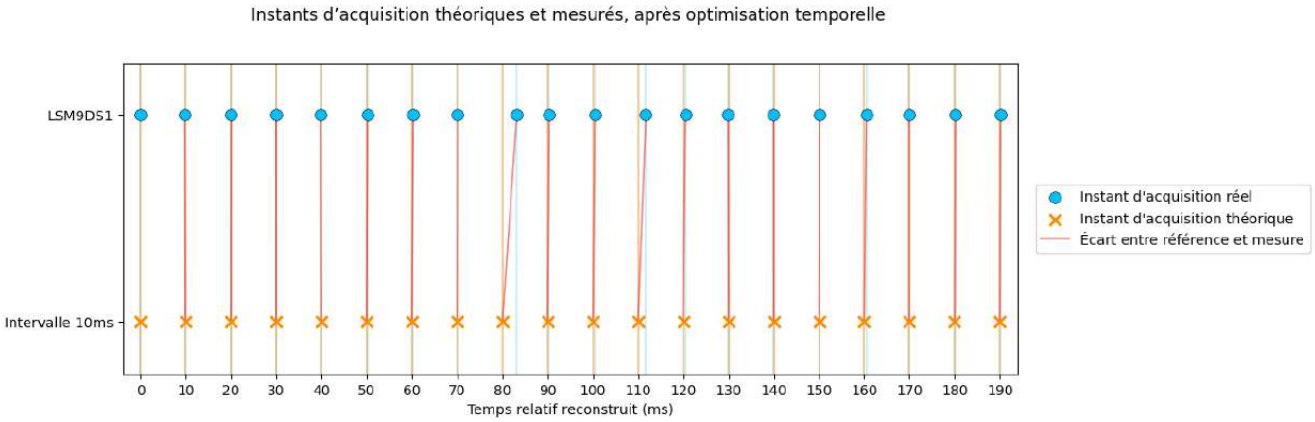
Intervalle (ms)	**Source**	**Période moyenne (ms)**	**Fréquence moyenne (Hz)**	**Période max. (ms)**	**Période min. (ms)**
10	LSM9DS1	**10,00**	**100,00**	**45,84**	**3,47**
	CoMote	10,20	98,00	43,00	1,00
	R-IoT	10,00	99,98	133,75	0,75
20	LSM9DS1	20,00	50,00	50,03	4,33
	CoMote	20,22	49,43	52,00	1,00
	R-IoT	20,00	49,99	94,14	0,91
40	LSM9DS1	39,99	25,00	55,65	25,08
	CoMote	40,20	24,87	72,00	8,00
	R-IoT	40,00	25,00	87,47	1,14

Tableau 7: Comparaison des résultats liés à la période d'acquisition selon la source et l'intervalle d'échantillonnage, après l'optimisation temporelle du LSM9DS1

Annexe 5 : Représentation des instants d'acquisition théoriques et mesurés du LSM9DS1 avant et après l'optimisation temporelle



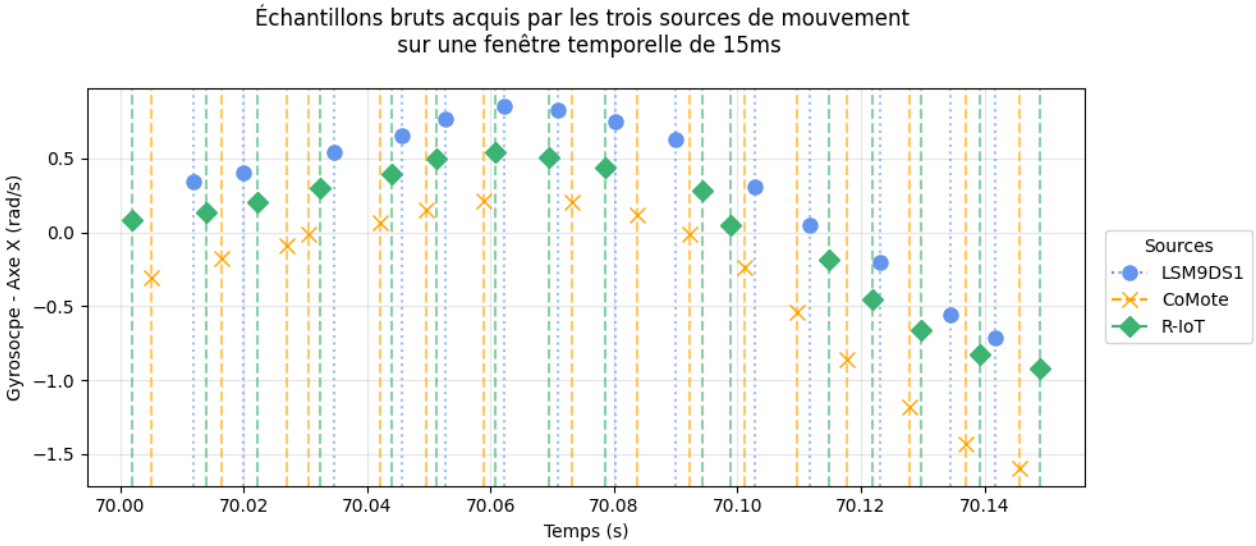
(a)



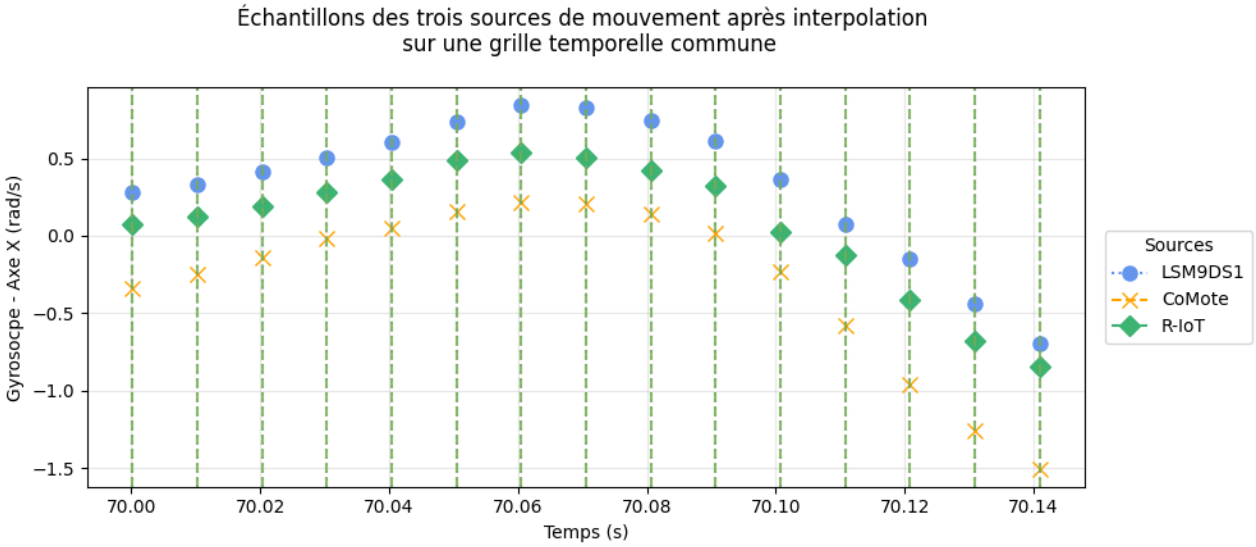
(b)

Figure 30: Comparaison des instants d'acquisition théoriques et mesurés du LSM9DS1 avant (a) et après (b) l'optimisation temporelle. Représentation effectuée pour un intervalle de référence de 10 ms, sur une fenêtre temporelle de 200 ms.

Annexe 6 : Représentation d'échantillons acquis par les trois sources de mouvement avant et après l'interpolation linéaire



(a)



(b)

Figure 31: Comparaison temporelle des échantillons acquis par les trois sources de mouvement, avant (a) et après (b) interpolation sur une grille temporelle commune. Cette représentation porte sur une fenêtre temporelle de 15 ms et sur l'axe X du gyroscope. Les marqueurs représentent les échantillons acquis, tandis que les lignes verticales indiquent leurs instants d'acquisition respectifs.

Annexe 7 : Erreurs mesurées entre les données inertielles - Banc de test au repos

Note : Les erreurs sont calculées en soustrayant les mesures de la seconde source à celles de la première. La MAE désigne l'erreur absolue moyenne et la RMSE la racine de l'erreur quadratique moyenne. Ces résultats sont obtenus en considérant 3 minutes de données, pour un intervalle de 10 ms, soit environ 18 000 échantillons.

Comparaison	**Capteur**	**Axe**	**Erreur moyenne**	**MAE**	**RMSE**	**Erreur absolue max.**
LSM9DS1 – CoMote	Accéléromètre (m/s^2)	X	−0,79	0,79	0,79	0,94
		Y	−0,54	0,54	0,54	0,79
		Z	0,06	0,06	0,07	0,67
	Gyroscope (rad/s)	X	0,04	0,04	0,04	0,05
		Y	−0,06	0,06	0,06	0,07
		Z	0,05	0,05	0,05	0,06
LSM9DS1 – R-IoT	Accéléromètre (m/s^2)	X	−0,58	0,58	0,58	0,68
		Y	0,68	0,68	0,68	0,80
		Z	0,28	0,28	0,28	0,89
	Gyroscope (rad/s)	X	0,03	0,03	0,03	0,04
		Y	−0,02	0,02	0,02	0,03
		Z	0,03	0,03	0,03	0,04
R-IoT – CoMote	Accéléromètre (m/s^2)	X	−0,20	0,20	0,20	0,38
		Y	−1,23	1,23	1,23	1,52
		Z	−0,21	0,21	0,22	0,57
	Gyroscope (rad/s)	X	0,00	0,00	0,00	0,02
		Y	−0,04	0,04	0,04	0,05
		Z	0,01	0,01	0,01	0,02

Tableau 8: Erreurs mesurées entre les données inertielles des différentes sources au repos

Annexe 8 : Corrélations entre les données inertielles - Séquence de mouvements libres

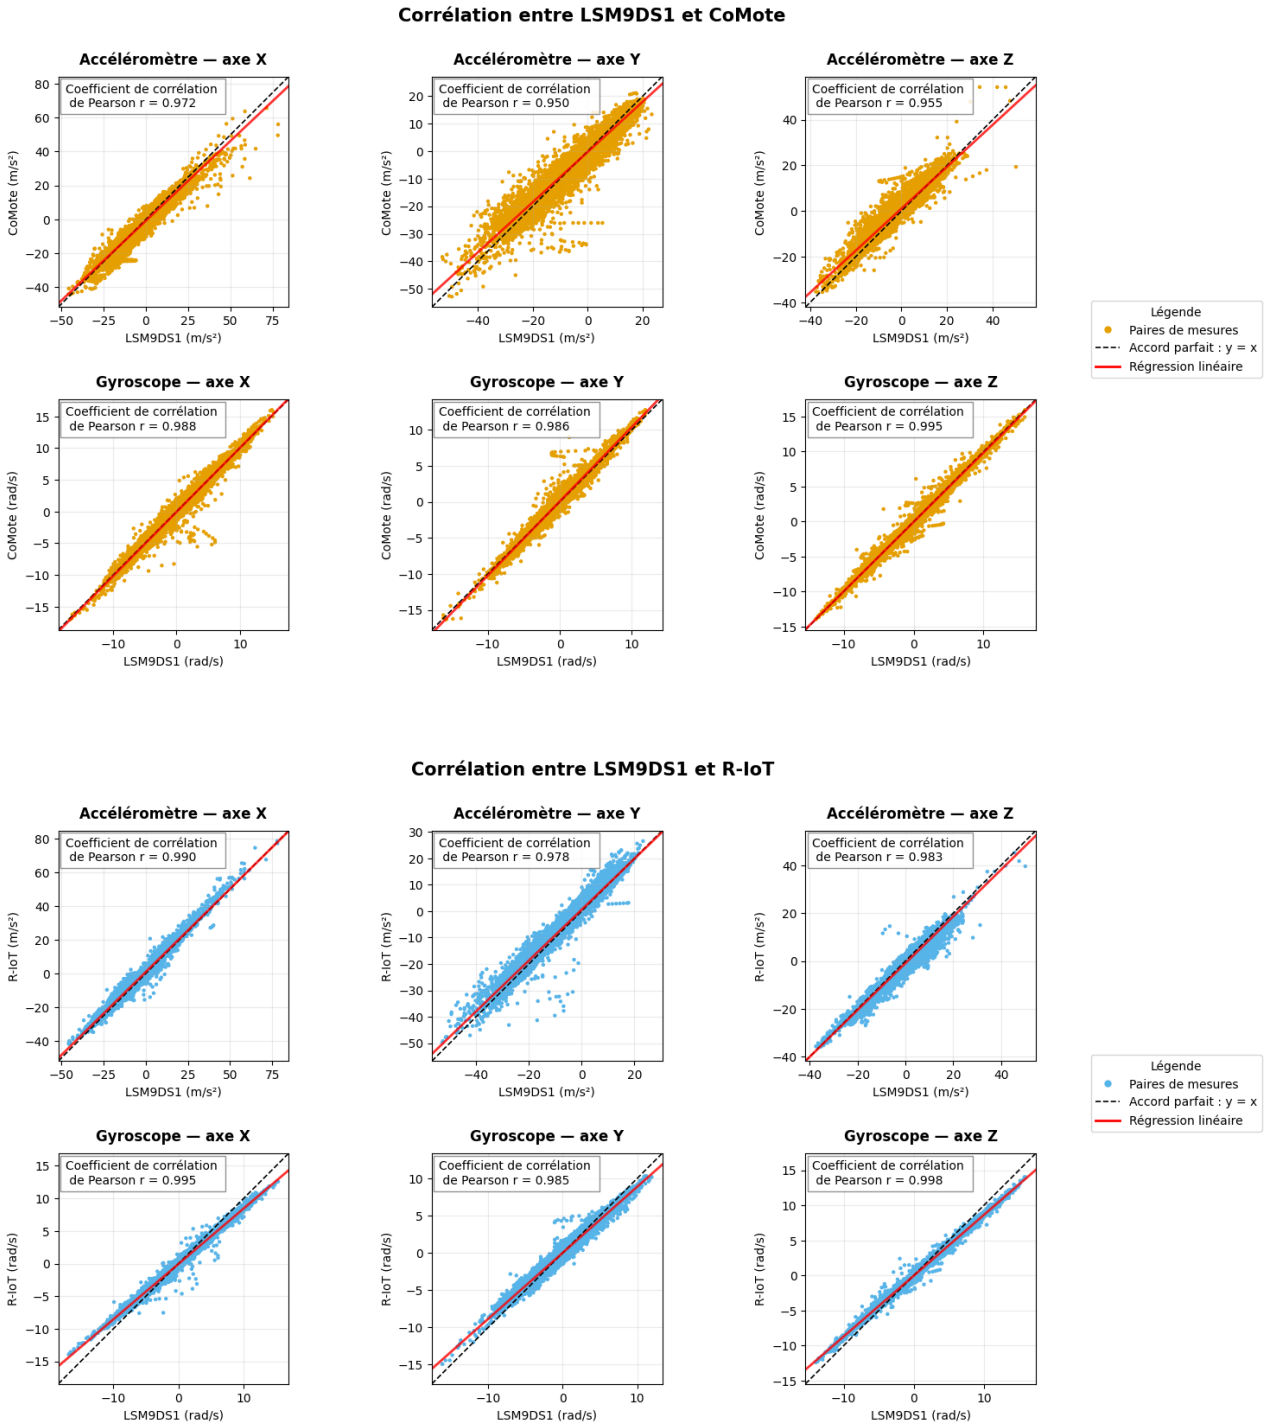


Figure 32: Corrélations entre les données gyroscopiques et accélérométriques des trois sources de mouvement, lors de la séquence de mouvements libres (pour un intervalle de 10 ms et sur une fenêtre temporelle de 3 minutes)

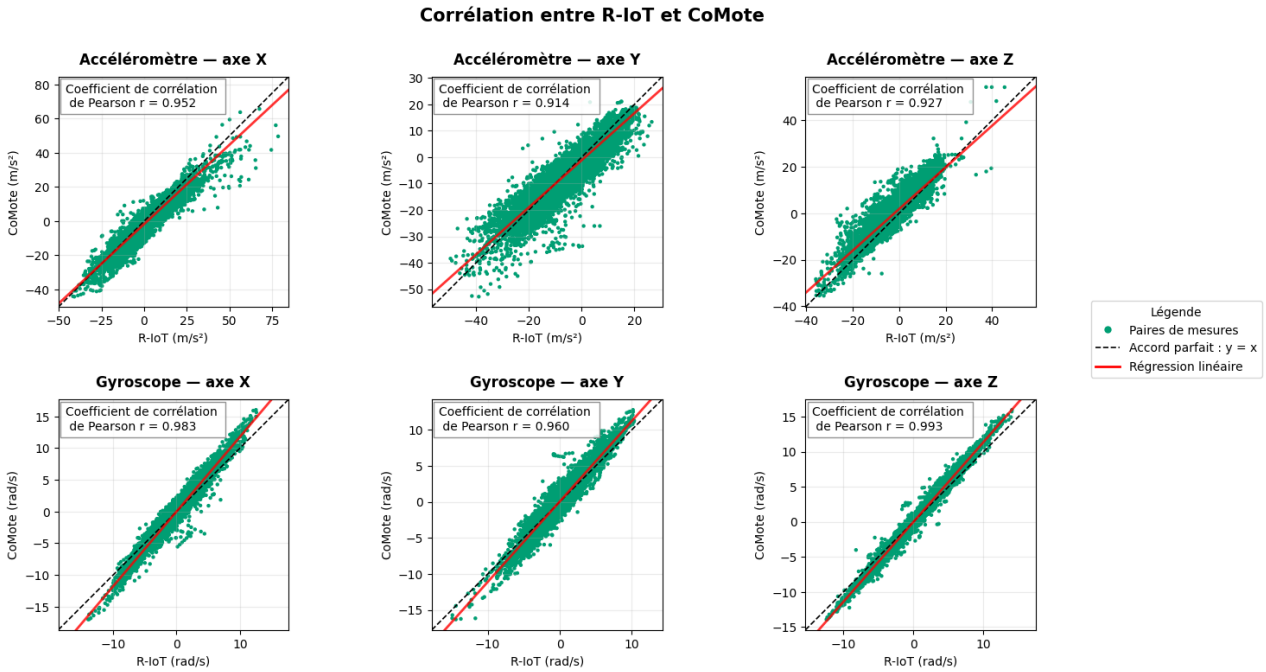


Figure 32: Corrélations entre les données gyroscopiques et accélérométriques des trois sources de mouvement, lors de la séquence de mouvements libres (pour un intervalle de 10 ms et sur une fenêtre temporelle de 3 minutes) — suite.

Annexe 9 : Erreurs mesurées entre les données inertielles - Séquence de mouvements libres

Note : Les erreurs sont calculées en soustrayant les mesures de la seconde source à celles de la première. La MAE désigne l'erreur absolue moyenne et la RMSE la racine de l'erreur quadratique moyenne. Ces résultats sont obtenus en considérant 3 minutes de données, pour un intervalle de 10 ms, soit environ 18 000 échantillons.

Comparaison	**Capteur**	**Axe**	**Erreur moyenne**	**MAE**	**RMSE**	**Erreur absolue max.**	**Coeff. Pearson *r***
LSM9DS1 – CoMote	Accéléromètre (m/s^2)	X	0,74	1,81	2,69	37,00	0,972
		Y	−0,21	1,89	2,93	33,37	0,950
		Z	−1,05	1,69	2,61	30,84	0,955
	Gyroscope (rad/s)	X	0,06	0,37	0,59	10,93	0,988
		Y	−0,07	0,31	0,50	7,92	0,986
		Z	0,05	0,24	0,39	6,10	0,995
LSM9DS1 – R-IoT	Accéléromètre (m/s^2)	X	−0,96	1,32	1,84	18,04	0,990
		Y	−0,80	1,41	2,12	30,92	0,978
		Z	0,91	1,21	1,75	21,71	0,983
	Gyroscope (rad/s)	X	0,03	0,46	0,64	6,01	0,995
		Y	0,00	0,38	0,54	5,25	0,985
		Z	0,01	0,42	0,57	4,39	0,998
R-IoT – CoMote	Accéléromètre (m/s^2)	X	1,71	2,62	3,77	36,89	0,952
		Y	0,59	2,69	3,85	33,95	0,914
		Z	−1,96	2,48	3,61	24,42	0,927
	Gyroscope (rad/s)	X	0,03	0,65	0,88	7,90	0,983
		Y	−0,06	0,63	0,87	7,50	0,960
		Z	0,04	0,48	0,65	4,18	0,993

Tableau 9: Erreurs mesurées entre les données inertielles des différentes sources lors de la séquence de mouvements libres